Facultad de Ingeniería
Magíster en Ciencia de Datos e Inteligencia Artificial

ANÁLISIS DE LA DESERCIÓN EN LA EDUCACIÓN SUPERIOR CHILENA

Informe técnico de avance

Evaluación Sumativa 1
Estadística Computacional

Autor:
Sebastian Antunez Noguera

Profesor/a:
[indicar nombre del docente]

Santiago, Chile
2026

1. Problema de decisión y objetivo

Más de la mitad de quienes ingresan a un programa de pregrado en Chile no llega a titularse de él, con consecuencias para el estudiante, para la institución que sostiene vacantes que no rinden y para el Estado que subsidia matrículas sin contrapartida. Este informe aborda una situación concreta de decisión bajo incertidumbre: **una autoridad dispone de presupuesto para un programa de retención que solo cubre una fracción del sistema y debe decidir dónde concentrarlo.** La incertidumbre es doble: el abandono no se observa directamente sino que se estima de registros agregados, y no se sabe de antemano qué criterio de focalización separa mejor a los programas problemáticos.

De ahí las tres preguntas que estructuran el trabajo, cada una asociada a un procedimiento: (i) cuál es la magnitud del abandono y cuánto varía entre programas, que responde la estadística descriptiva; (ii) con qué precisión puede estimarse, que responden los intervalos de confianza; y (iii) qué características distinguen a los programas con más abandono y cuáles de esas diferencias bastan para orientar la decisión, que responden los contrastes junto al tamaño del efecto.

2. Datos y metodología

2.1 Origen y construcción de la variable respuesta

El conjunto proviene de dos bases abiertas del Servicio de Información de Educación Superior (SIES) del Ministerio de Educación: matrícula 2007–2026 y titulados 2007–2025. Ambas se publican agregadas por programa y año, sin registros individuales.

Para cada programa se compara el número de titulados del año y con el ingreso a primer año de la cohorte que debió entrar en $y - L$, siendo L la duración formal en años. La titulación aparente es el cociente entre ambas sumas acumuladas entre 2010 y 2025, y el **abandono** es su complemento. Se conservan solo los programas con al menos 100 estudiantes de ingreso acumulado.

El adjetivo «aparente» no es un adorno: con datos agregados, quien se cambia de carrera y se titula en otra parte cuenta aquí como abandono, de modo que la cifra estimada es una cota superior del abandono real.

2.2 Unidad de análisis y variables

Cada observación es un **programa** —la combinación de carrera, institución, sede, jornada y modalidad—, no un estudiante. El conjunto reúne **9.678 programas**, que representan 3.925.426 estudiantes de ingreso acumulado, y no presenta valores faltantes. Las 25 variables se clasifican así:

Tipo	N.º	Ejemplos
Cuantitativa continua	10	abandono (respuesta), inst_acreditada, pct_mujeres, edad_promedio
Cuantitativa discreta	4	ingreso, titulados, duracion_estudio_carrera
Cualitativa nominal	7	tipo de institución, área del conocimiento, región, jornada
Cualitativa dicotómica	2	metropolitana, inst_cerrada
Identificador	2	codigo_carrera, codigo_de_institucion

Conviene advertir que inst_acreditada parece dicotómica y no lo es: toma 1.195 valores distintos entre 0 y 1 porque promedia el estado de acreditación a lo largo de los años de cohorte. Por eso los contrastes del apartado 5 comparan los dos extremos inequívocos —siempre acreditada (7.672 programas) frente a nunca acreditada (757)— y excluyen los 1.249 programas en transición.

2.3 Calidad de los datos

Antes de describir nada se auditó el conjunto en las cuatro familias de problemas que podrían invalidar el análisis: registros repetidos, información ausente, valores fuera del dominio admisible e inconsistencias aritméticas.

Control	Casos	Resultado
Filas duplicadas y códigos de programa repetidos	0	correcto
Valores faltantes	0	correcto

Control	Casos	Resultado
Valores fuera de dominio (proporciones, abandono, edad, umbral de ingreso)	0	correcto
Duración fuera de 1 a 10 años	1	revisar
Titulados por sobre el ingreso de la cohorte	299	revisar

El conjunto llega limpio y **no requiere limpieza**, lo que es esperable porque ya es el resultado de un proceso de agregación y filtrado documentado. Dos controles quedan marcados y ninguno exige corregir el dato. Un programa declara doce años de duración formal: es un caso real de Arte y Arquitectura, no un error de captura. Y 299 programas titulan a más personas de las que ingresaron en la ventana, lo que no es una inconsistencia del dato sino una consecuencia del método, al recoger la cohorte de egreso a quienes llegaron por convalidación o traslado; es el origen del apilamiento en cero que se examina más adelante.

3. Estadística descriptiva

La descripción de la variable respuesta combina medidas de tendencia central, de dispersión y de forma. Las tres familias son necesarias: la primera sitúa el centro, la segunda indica cuánto se alejan de él los programas —que es justamente lo que interesa a quien debe focalizar— y la tercera dice si las medidas centrales son representativas.

Tendencia central	Valor	Dispersión	Valor	Forma	Valor
Media	0,5183	Desviación estándar	0,2239	Asimetría	−0,182
Mediana	0,5250	Rango intercuartílico	0,2927	Curtosis (exceso)	−0,184
Primer cuartil	0,3764	Coef. de variación	0,4320	Mínimo	0,000
Tercer cuartil	0,6692	Varianza	0,0501	Máximo	1,000

El centro. Media y mediana casi coinciden, de modo que ninguna cola arrastra el promedio: en el programa típico, algo más de la mitad de la cohorte no llega a titularse.

La dispersión. Un coeficiente de variación de 0,43 y una mitad central que va de 0,376 a 0,669 revelan que el abandono varía enormemente entre programas. Esa heterogeneidad es precisamente lo que da sentido a focalizar: si todos los programas se parecieran, daría igual dónde intervenir.

La forma. Con asimetría y curtosis en torno a −0,18, la distribución es casi simétrica y ligeramente más plana que la normal. No hay valores extremos que distorsionen el análisis, lo que habilita el uso de la media y de los procedimientos paramétricos del apartado 5.

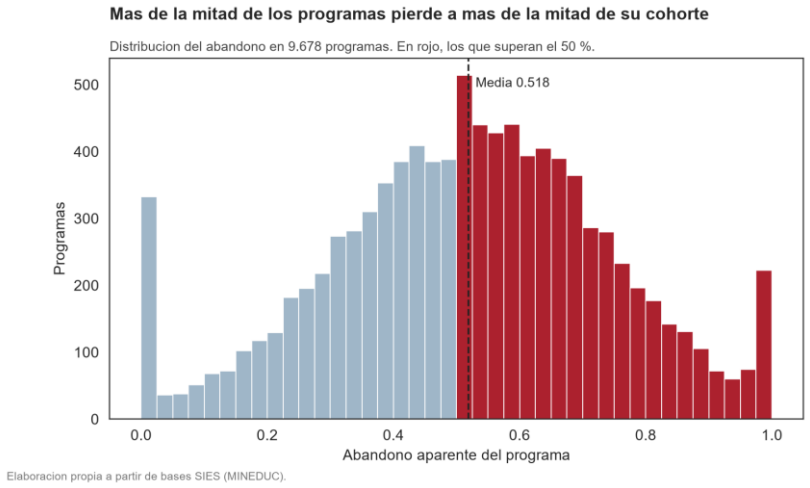


Figura 1. Distribución del abandono aparente en los 9.678 programas analizados.

La figura 1 muestra dos acumulaciones en los extremos, **305 programas (3,2 %) con abandono cero** y **160 (1,7 %) con abandono uno**, que conviene diagnosticar porque podrían delatar un desajuste entre las bases de origen. Se cruzó cada uno con su último año de matrícula y con las titulaciones acumuladas en cualquier año. **Los 160 con abandono uno son, en su gran mayoría, programas que cerraron**: el 91 % dejó de matricular antes o durante el año de egreso esperado; solo 14 seguían activos y 11 de ellos sí registran titulaciones, de modo que en esos el cero refleja el desfase de la ventana y no la realidad. **Los 305 con abandono cero** registran todos titulaciones y la mitad seguía matriculando: titulan al menos tantas personas como ingresaron, por convalidaciones o traslados. Ambos extremos son el 4,8 % de los casos y el 3,3 % de la matrícula, y excluirlos desplazaría la media nueve milésimas: no comprometen ninguna conclusión, pero son el residuo visible de que la variable es aparente.

3.1 Las demás variables numéricas

Dos rasgos del perfil de los programas condicionan lo que sigue. El **87 % de la matrícula cursa en instituciones acreditadas** pero solo el **32 % en carreras acreditadas**: la acreditación de carrera es mucho más escasa y, por eso mismo, discrimina mejor. Y las variables de tamaño son fuertemente asimétricas, con coeficientes de variación por encima de 1, razón por la cual el análisis emplea el logaritmo de la matrícula y no su valor bruto cuando necesita una escala comparable. El cuaderno recoge el resumen completo de las doce variables numéricas.

3.2 Las variables cualitativas: frecuencias

Para las variables cualitativas la descripción pertinente no son medias sino frecuencias absolutas y relativas, que advierten además qué categorías tienen pocos casos, algo decisivo al elegir un contraste.

Tipo de institución	n	%	Otras categorías	n	%
Institutos profesionales	3.759	38,8	Técnico de nivel superior	5.009	51,8
CFT privados	2.263	23,4	Profesional con licenciatura	2.890	29,9
Universidades privadas	2.012	20,8	Profesional sin licenciatura	1.779	18,4
U. estatales CRUCH	932	9,6	Jornada diurna	5.930	61,3
U. privadas CRUCH	685	7,1	Jornada vespertina	3.439	35,5
CFT estatales	27	0,3	Modalidad presencial	9.331	96,4

El reparto es muy desigual y eso condiciona el análisis. Los centros de formación técnica estatales son apenas 27 programas y la modalidad presencial cubre el 96,4 % del conjunto, de modo que las comparaciones por modalidad descansan sobre menos de 350 casos. Esa asimetría explica que el contraste del apartado 5 sobre tipo de institución se plantee como prueba de independencia y no como comparación de medias: con una categoría de 27 casos, un contraste de medias tendría una potencia muy desigual entre grupos.

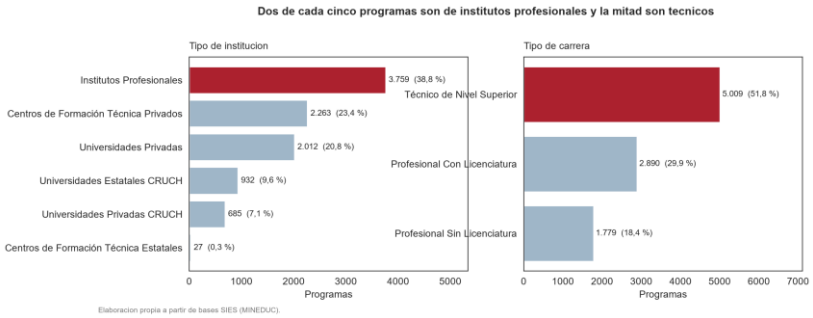


Figura 2. Distribución de los programas por tipo de institución y tipo de carrera.

3.3 El abandono por grupos

La media global oculta las diferencias que importan para decidir. El abandono medio recorre **12,3 puntos porcentuales** entre tipos de institución y **17,5 puntos** entre áreas del conocimiento:

Tipo de institución	n	Media	DE	Área del conocimiento	n	Media
CFT estatales	27	0,565	0,127	Humanidades	78	0,643
CFT privados	2.263	0,542	0,195	Derecho	224	0,641
Institutos profesionales	3.759	0,528	0,232	Arte y Arquitectura	490	0,585
Universidades privadas	2.012	0,509	0,237	Tecnología	3.009	0,555
U. estatales CRUCH	932	0,494	0,223	Educación	1.344	0,476
U. privadas CRUCH	685	0,442	0,213	Salud	1.355	0,468

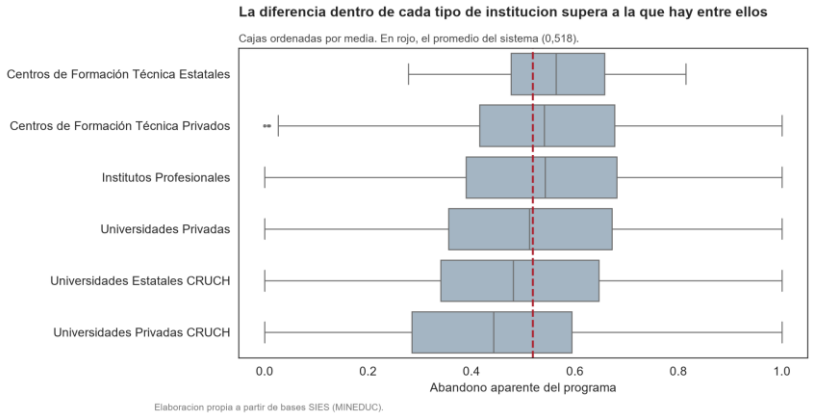


Figura 3. Dispersión del abandono dentro de cada tipo de institución.

La figura 3 contiene la advertencia más importante para la decisión: las cajas se solapan ampliamente, de modo que **la variación dentro de cada tipo de institución supera a la que hay entre tipos**. Focalizar por tipo de institución, que sería lo administrativamente más cómodo, dejaría fuera a buena parte de los programas con más abandono.

3.4 Análisis bivariado

Hasta aquí cada variable se ha descrito por separado. El paso siguiente examina cómo se relacionan entre sí, que es lo que permite anticipar qué factores merecen un contraste formal y cuáles podrían estar midiendo lo mismo.

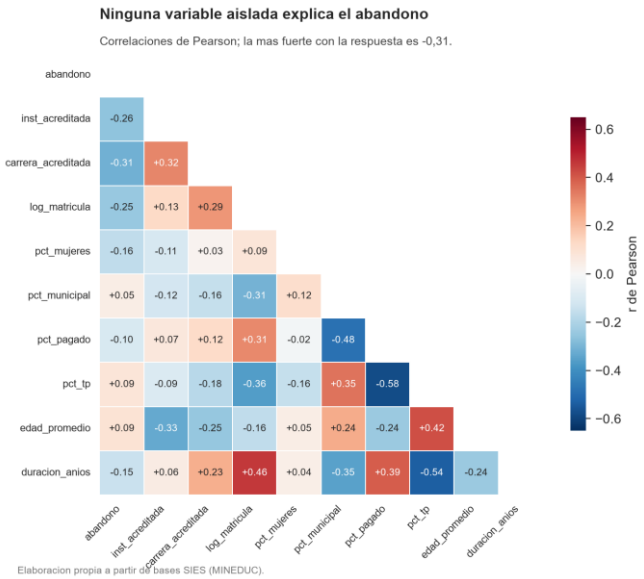


Figura 4. Matriz de correlaciones de Pearson entre las variables numéricas.

Ninguna variable aislada explica el abandono. La correlación más fuerte es la de la acreditación de carrera, con r = −0,311, que equivale a un 9,7 % de varianza compartida; las demás no superan 0,26 en valor absoluto. El fenómeno es multifactorial,

lo que anticipa que ningún criterio único de focalización será suficiente. En particular, el tamaño del programa se asocia negativamente con el abandono (r = −0,247) pero explica apenas un 6 % de la variación.

El signo de cada relación es el esperado: acreditación, tamaño, proporción de mujeres y duración formal se asocian negativamente con el abandono, mientras que la edad media de la matrícula y el origen técnico-profesional lo hacen positivamente. Ninguna correlación contradice lo previsible, lo que da verosimilitud al conjunto.

Hay colinealidad entre las predictoras. El par más correlacionado es la proporción de egresados de colegios particulares pagados con la de establecimientos técnico-profesionales (r = −0,583), seguida de esta última con la duración formal (r = −0,535). Esa estructura importa para la fase siguiente, porque un modelo multivariado no podrá separar limpiamente esos efectos.

4. Estimación puntual e intervalos de confianza

4.1 Sobre qué población se infiere

Antes de calcular un intervalo conviene responder una pregunta que suele saltarse: **¿de qué población se habla?** Los 9.678 programas no son una muestra sino todos los que cumplen los criterios de inclusión en el período, y sobre un censo un intervalo de confianza en sentido estricto carecería de sentido, porque el parámetro ya está medido sin error muestral. La inferencia se formula, por tanto, sobre el **proceso generador**: los programas observados como una realización de un sistema que sigue operando y pudo haber producido resultados algo distintos. La distinción cambia lo que puede afirmarse: autoriza a decir que el abandono esperado está entre 0,514 y 0,523, y prohíbe decir que hay un 95 % de probabilidad de que el valor real caiga ahí, lectura que el intervalo frecuentista no admite.

4.2 Cinco parámetros estimados

Se estiman primero las medias de **tres variables numéricas** que describen dimensiones distintas del programa —la respuesta, el perfil etario y la composición de género— y después dos parámetros de otra naturaleza, que exigen procedimientos propios:

Parámetro	Estimación puntual	IC 95 %	Procedimiento
Abandono medio del programa	0,5183	[0,5138 ; 0,5227]	t de Student, gl = 9.677
Edad media de la matrícula (años)	24,1600	[24,0905 ; 24,2295]	t de Student, gl = 9.677
Proporción de mujeres	0,5156	[0,5097 ; 0,5215]	t de Student, gl = 9.677
Programas con abandono > 50 %	0,5494	[0,5395 ; 0,5593]	Wilson (proporción)
Diferencia por acreditación	+0,1757	[0,1590 ; 0,1924]	Welch, gl = 902

Las tres medias. La edad media de 24,16 años es alta para pregrado y refleja el peso de la jornada vespertina, que agrupa al 35,5 % de los programas. La proporción de mujeres, 0,5156, describe un sistema equilibrado en promedio, pero su desviación estándar de 0,296 revela una segregación fuerte por programa: hay carreras casi enteramente masculinas y otras casi enteramente femeninas. Ese tercer caso ilustra bien el riesgo de leer mal un intervalo estrecho, porque lo que afirma es que *el promedio del sistema* se conoce con precisión, no que los programas se parezcan entre sí.

El abandono. Su intervalo mide nueve milésimas de ancho. Esa precisión no proviene de que el fenómeno sea homogéneo —la desviación de 0,224 dice lo contrario— sino del tamaño del conjunto, que divide la desviación por 98,4. Un remuestreo bootstrap de 5.000 réplicas arroja [0,5139 ; 0,5226], coincidente hasta la cuarta cifra, lo que confirma que el supuesto de normalidad de la media es sostenible.

La proporción y la diferencia. Para la proporción se emplea el método de Wilson (1927) y no la aproximación normal, porque no produce límites fuera de [0, 1] y conserva su cobertura cerca de los extremos; con p próxima a 0,5 y n grande ambos coinciden, pero la elección deja de ser indiferente en otros escenarios. El intervalo de la diferencia no contiene el cero y su límite inferior ya alcanza los 15,9 puntos porcentuales, de modo que la conclusión no depende del extremo que se tome.

5. Pruebas de hipótesis y tamaño del efecto

El procedimiento adecuado depende del tipo de las variables implicadas, no de la costumbre. Se aplican tres contrastes distintos, uno por cada combinación presente en los datos, todos al nivel **α = 0,05** fijado antes de examinar los resultados.

Sobre los supuestos: Kolmogorov-Smirnov rechaza la normalidad exacta ($D = 0{,}021$; $p < 0{,}001$), pero a este tamaño detecta desviaciones irrelevantes y lo que los procedimientos requieren es la normalidad de la media, que el teorema central del límite garantiza y la asimetría casi nula refuerza. Levene no rechaza la igualdad de varianzas ($W = 0{,}869$; $p = 0{,}351$); aun así se emplea la versión de Welch (1947), que no la supone, por conservadora.

Contraste	Hipótesis nula	Estadístico	Valor p	Tamaño del efecto
t de Welch	Igual abandono según acreditación	$t = 20{,}61$ ($gl = 902$)	$1{,}2 \times 10^{-77}$	d de Cohen = 0,80 — grande
ANOVA de un factor	Igual abandono en las 10 áreas	$F = 44{,}30$ ($gl = 9; 9.668$)	$1{,}2 \times 10^{-78}$	$\eta^2 = 0{,}040$ — pequeño
Chi-cuadrado	Independencia institución / abandono	$\chi^2 = 102{,}51$ ($gl = 5$)	$1{,}6 \times 10^{-20}$	V de Cramér = 0,103 — débil

Los tres rechazan la hipótesis nula y, sin embargo, solo uno orienta la decisión. Esta es la conclusión metodológica central del informe.

Los programas de instituciones nunca acreditadas presentan un abandono 17,6 puntos porcentuales mayor, con una **d de Cohen de 0,80** que la convención establecida por Cohen (1988) sitúa en el umbral de los efectos grandes: la acreditación no solo distingue grupos de forma detectable, sino de forma sustantiva. El área del conocimiento, en cambio, explica apenas el **4 % de la varianza** del abandono, y el tipo de institución arroja una asociación que la V de Cramér (1946) califica de débil, coherente con el solapamiento que ya mostraba la figura 3.

Con 9.678 observaciones la potencia es tan alta que **el valor p pierde casi toda capacidad de discriminar**: los tres contrastes arrojan valores entre 10^{-20} y 10^{-78}, y aun así sus efectos van de grande a despreciable. Informar solo la significación llevaría a tratar los tres resultados como equivalentes, que es exactamente el error que una decisión de focalización no puede permitirse. La advertencia es la misma que formula la American Statistical Association al recordar que un valor p, por sí solo, no mide la magnitud de un efecto ni su relevancia práctica (Wasserstein y Lazar, 2016).

Las comparaciones múltiples de Tukey (1949), que controlan el error por familia, confirman diferencias significativas en 30 de los 45 pares de áreas; la mayor separa Humanidades de Salud, con 17,4 puntos porcentuales.

6. Interpretación preliminar

Para la autoridad que debe repartir un presupuesto limitado de retención, los resultados se traducen en cuatro afirmaciones.

La magnitud justifica actuar y la heterogeneidad justifica focalizar. El abandono esperado se estima en 0,518, con intervalo de 0,514 a 0,523, y el 54,9 % de los programas supera el 50 %: no son casos aislados. Pero con un coeficiente de variación de 0,43 y una mitad central que abarca casi treinta puntos porcentuales, los programas difieren demasiado como para tratarlos igual.

El criterio de focalización importa, y no todos valen. La acreditación institucional separa grupos con una diferencia de 17,6 puntos y un efecto grande: es un criterio útil. El área del conocimiento y el tipo de institución producen contrastes igual de significativos pero con efectos pequeños, porque la mayor parte de la variación ocurre dentro de cada categoría y no entre ellas; usarlos como criterio principal repartiría recursos con poca ganancia.

La incertidumbre acompaña, pero no impide decidir. Los intervalos son estrechos y ninguna de las conclusiones anteriores cambia según el extremo del intervalo que se adopte.

La recomendación preliminar, por tanto, no es focalizar por categorías administrativas sino por el **nivel de abandono medido en cada programa**, empleando la acreditación como señal complementaria. Las categorías agregadas resultan demasiado gruesas para capturar dónde está realmente el problema.

7. Limitaciones

El abandono es aparente, no observado, de modo que la magnitud estimada es una cota superior; el diagnóstico del apartado 3 acota ese efecto en los extremos pero no en el resto de la escala, donde no es observable. **La unidad de análisis es el programa**, por lo que trasladar las conclusiones a individuos sería una falacia ecológica. **Las asociaciones no son causas**: sin grupo de control ni asignación aleatoria, la acreditación podría estar recogiendo el efecto de la selectividad del ingreso o de los recursos de la institución. **La ventana temporal trunca las cohortes recientes**, cuyo abandono queda inflado. Y **los contrastes son univariados**, de modo que los efectos podrían estar confundidos entre sí.

8. Próximos pasos

El análisis realizado es univariado: cada factor se examina por separado. Esa es su principal limitación y define la agenda de la fase siguiente.

1. Modelo multivariado. Una regresión sobre el conjunto de predictoras estimaría el efecto de cada una manteniendo las demás constantes. Es necesario porque el apartado 3.4 mostró colinealidad: los programas que reciben egresados de enseñanza técnico-profesional son también los más cortos, y hoy no puede separarse qué parte del abandono corresponde a cada rasgo.

2. Agrupación por institución. Los programas de una misma institución comparten políticas y selectividad, de modo que no son observaciones independientes; los errores estándar de este informe no lo recogen y un modelo con errores agrupados corregiría esa subestimación.

3. Ponderación por tamaño. Aquí cada programa pesa igual, sea de 100 o de 9.994 estudiantes. Ponderar por el ingreso respondería una pregunta complementaria: cuántos estudiantes, y no cuántos programas, están expuestos a un abandono alto.

4. Corregir el truncamiento. Restringir la lectura longitudinal a las cohortes con ventana completa y contrastar contra las bases de retención del propio SIES permitiría acotar cuánto del abandono medido es cambio de carrera y cuánto salida del sistema.

5. Capacidad predictiva. Con el modelo ajustado podría evaluarse si el abandono es anticipable desde las características observables, que es la pregunta que convierte el diagnóstico en un instrumento de focalización.

9. Reproducibilidad

Todas las cifras, tablas y figuras se generan al ejecutar `notebooks/Sumativa1_Analisis_Desercion.ipynb`, que corre de principio a fin sin errores y deja sus salidas en `resultados/`, incluido el detalle que este informe resume. El conjunto analítico está versionado, de modo que reproducirlo no exige descargar las bases originales del SIES; las versiones de las bibliotecas están fijadas en `requirements.txt` y la semilla en 42. Repositorio: https://github.com/santunez75/analisis-desercion

10. Referencias

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Cramér, H. (1946). *Mathematical methods of statistics*. Princeton University Press.

Servicio de Información de Educación Superior. (2026). *Bases de datos de matrícula en educación superior 2007–2026*. Ministerio de Educación de Chile. https://datosabiertos.mineduc.cl/

Servicio de Información de Educación Superior. (2026). *Bases de datos de titulados de educación superior 2007–2025*. Ministerio de Educación de Chile. https://datosabiertos.mineduc.cl/

Tukey, J. W. (1949). Comparing individual means in the analysis of variance. *Biometrics*, 5(2), 99–114.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA statement on p-values: context, process, and purpose. *The American Statistician*, 70(2), 129–133.

Welch, B. L. (1947). The generalization of «Student's» problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212.