Facultad de Ingeniería
Magíster en Ciencia de Datos e Inteligencia Artificial

ANÁLISIS DE LA DESERCIÓN EN LA EDUCACIÓN SUPERIOR CHILENA

Informe técnico de avance

Evaluación Sumativa 1
Estadística Computacional

Autor:
Sebastian Antunez Noguera

Profesor/a:
[indicar nombre del docente]

Santiago, Chile
2026

1. Problema de decisión y objetivo

Más de la mitad de quienes ingresan a un programa de pregrado en Chile no llega a titularse de él. El hecho tiene consecuencias para el estudiante, que pierde tiempo y dinero; para la institución, que sostiene vacantes que no rinden; y para el Estado, que subsidia matrículas sin contrapartida.

Este informe aborda una situación concreta de decisión bajo incertidumbre: **una autoridad dispone de presupuesto para un programa de retención que solo alcanza a cubrir una fracción de los programas del sistema, y debe decidir dónde concentrarlo.** La incertidumbre es doble. Por un lado, el abandono de cada programa no se observa directamente, sino que se estima a partir de registros agregados. Por otro, no se sabe de antemano qué criterio de focalización separa mejor a los programas problemáticos de los demás.

De ahí las tres preguntas que estructuran el trabajo, cada una asociada a un procedimiento estadístico: (i) cuál es la magnitud del abandono y cuánto varía entre programas, que responde la estadística descriptiva; (ii) con qué precisión puede estimarse el abandono del sistema, que responden los intervalos de confianza; y (iii) qué características distinguen a los programas con más abandono y cuáles de esas diferencias son lo bastante grandes como para orientar la decisión, que responden los contrastes de hipótesis junto al tamaño del efecto.

2. Datos y metodología

2.1 Origen y construcción de la variable respuesta

El conjunto proviene de dos bases abiertas del Servicio de Información de Educación Superior (SIES) del Ministerio de Educación: matrícula 2007–2026 y titulados 2007–2025. Ambas se publican agregadas por programa y año, sin registros individuales.

Para cada programa se compara el número de titulados del año y con el ingreso a primer año de la cohorte que debió entrar en $y - L$, donde L es la duración formal de la carrera en años. La titulación aparente es el cociente entre ambas sumas acumuladas entre 2010 y 2025, y el **abandono** es su complemento. Se conservan solo los programas con al menos 100 estudiantes de ingreso acumulado, para que el cociente no dependa de unas pocas personas.

El adjetivo «aparente» no es un adorno. Con datos agregados, quien se cambia de carrera o de institución y se titula en otra parte cuenta aquí como abandono, y quien se titula muy tarde puede quedar fuera de la ventana observada. La cifra estimada es, por tanto, una cota superior del abandono real.

2.2 Unidad de análisis y variables

Cada observación es un **programa** —la combinación de carrera, institución, sede, jornada y modalidad—, no un estudiante. El conjunto reúne **9.678 programas**, que representan 3.925.426 estudiantes de ingreso acumulado, y no presenta valores faltantes. Las 25 variables se clasifican así:

Tipo	N.º	Ejemplos
Cuantitativa continua	10	abandono (respuesta), inst_acreditada, pct_mujeres, edad_promedio
Cuantitativa discreta	4	ingreso, titulados, duracion_estudio_carrera
Cualitativa nominal	7	tipo de institución, área del conocimiento, región, jornada
Cualitativa dicotómica	2	metropolitana, inst_cerrada
Identificador	2	codigo_carrera, codigo_de_institucion

Conviene advertir que inst_acreditada parece dicotómica y no lo es: toma 1.195 valores distintos entre 0 y 1 porque promedia el estado de acreditación a lo largo de los años de cohorte. Por eso los contrastes del apartado 5 comparan los dos extremos inequívocos —siempre acreditada (7.672 programas) frente a nunca acreditada (757)— y excluyen los 1.249 programas en transición.

3. Estadística descriptiva

La descripción de la variable respuesta combina medidas de tendencia central, de dispersión y de forma. Las tres familias son necesarias: la primera sitúa el centro, la segunda indica cuánto se alejan de él los programas —que es justamente lo que interesa a quien debe focalizar— y la tercera dice si las medidas centrales son representativas.

Tendencia central	Valor	Dispersión	Valor	Forma	Valor
Media	0,5183	Desviación estándar	0,2239	Asimetría	−0,182
Mediana	0,5250	Rango intercuartílico	0,2927	Curtosis (exceso)	−0,184
Primer cuartil	0,3764	Coef. de variación	0,4320	Mínimo	0,000
Tercer cuartil	0,6692	Varianza	0,0501	Máximo	1,000

El centro. Media y mediana casi coinciden, de modo que ninguna cola arrastra el promedio: en el programa típico, algo más de la mitad de la cohorte no llega a titularse.

La dispersión. Un coeficiente de variación de 0,43 y una mitad central que va de 0,376 a 0,669 revelan que el abandono varía enormemente entre programas. Esa heterogeneidad es precisamente lo que da sentido a focalizar: si todos los programas se parecieran, daría igual dónde intervenir.

La forma. Con asimetría y curtosis en torno a −0,18, la distribución es casi simétrica y ligeramente más plana que la normal. No hay valores extremos que distorsionen el análisis, lo que habilita el uso de la media y de los procedimientos paramétricos del apartado 5.

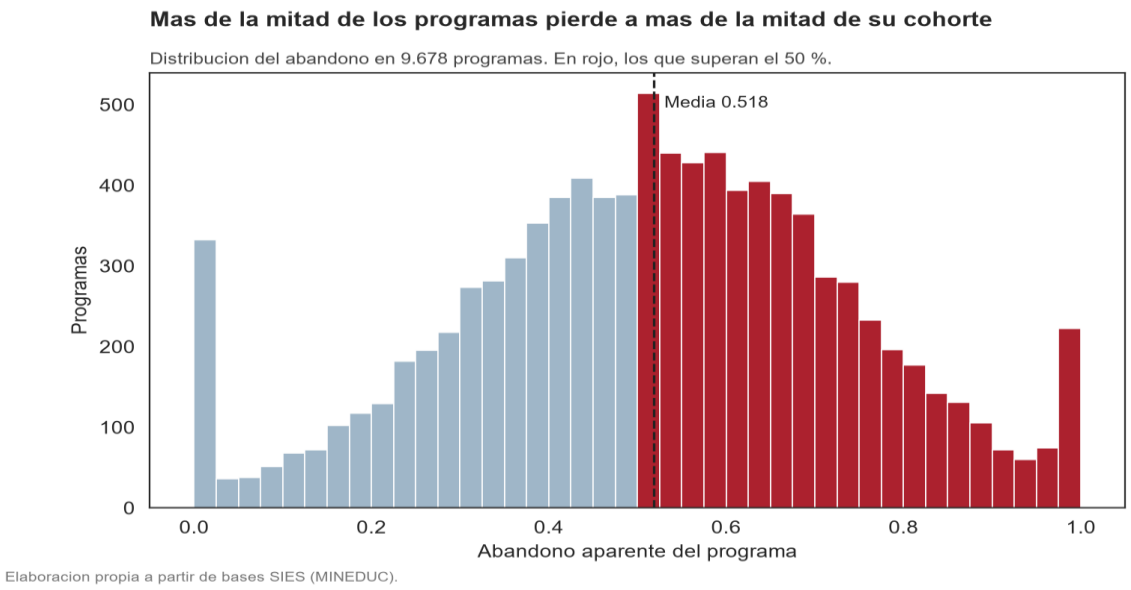


Figura 1. Distribución del abandono aparente en los 9.678 programas analizados.

La figura 1 muestra además dos acumulaciones en los extremos: **305 programas (3,2 %) con abandono exactamente cero** y **160 (1,7 %) con abandono uno**. Los primeros titulan al menos tantas personas como ingresaron, por convalidaciones o traslados desde otras cohortes; los segundos cerraron sin titular a nadie. Juntos no llegan al 5 % y no alteran las medidas centrales, pero son el residuo visible de que la variable es aparente y no una medición directa.

3.1 Comportamiento por grupos

La media global oculta las diferencias que importan para decidir. El abandono medio recorre **12,3 puntos porcentuales** entre tipos de institución y **17,5 puntos** entre áreas del conocimiento:

Tipo de institución	n	Media	DE	Área del conocimiento	n	Media
CFT estatales	27	0,565	0,127	Humanidades	78	0,643

Tipo de institución	n	Media	DE	Área del conocimiento	n	Media
CFT privados	2.263	0,542	0,195	Derecho	224	0,641
Institutos profesionales	3.759	0,528	0,232	Arte y Arquitectura	490	0,585
Universidades privadas	2.012	0,509	0,237	Tecnología	3.009	0,555
U. estatales CRUCH	932	0,494	0,223	Educación	1.344	0,476
U. privadas CRUCH	685	0,442	0,213	Salud	1.355	0,468

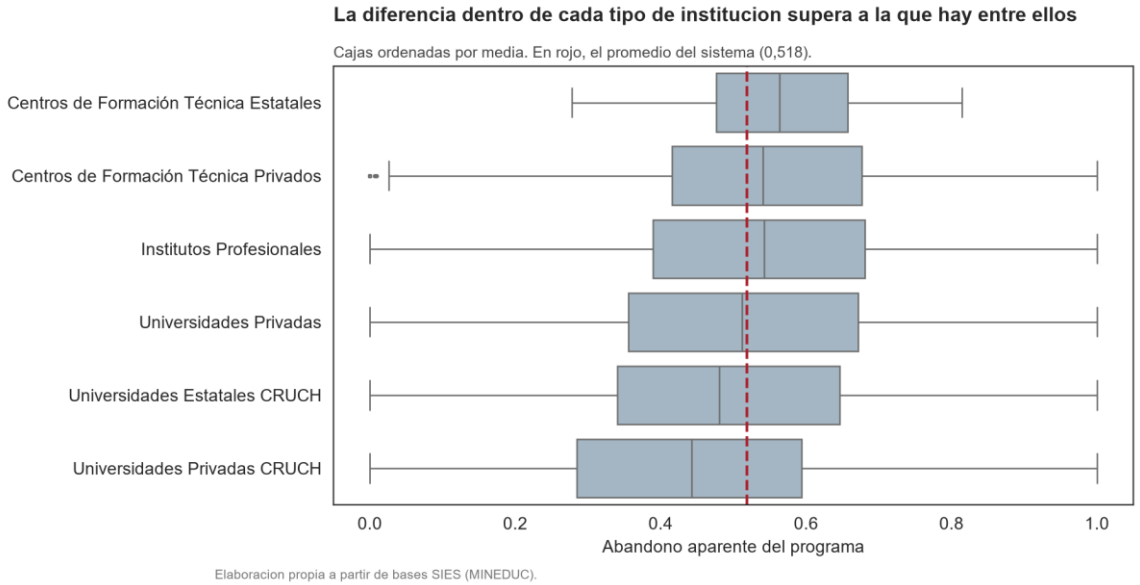


Figura 2. Dispersión del abandono dentro de cada tipo de institución.

La figura 2 contiene la advertencia más importante para la decisión: las cajas se solapan ampliamente, de modo que **la variación dentro de cada tipo de institución supera a la que hay entre tipos**. Focalizar por tipo de institución, que sería lo administrativamente más cómodo, dejaría fuera a buena parte de los programas con más abandono.

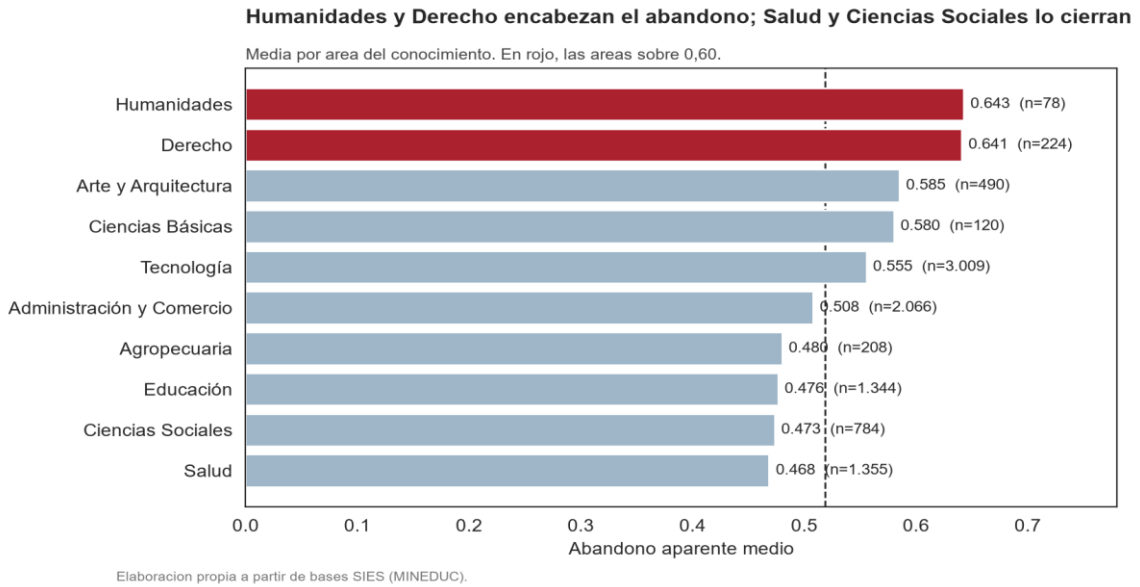


Figura 3. Abandono aparente medio por área del conocimiento.

Una última comprobación descarta la explicación más simple. El tamaño del programa se asocia negativamente con el abandono, pero la relación es débil: la correlación de Pearson con el logaritmo de la matrícula es de −0,247 y explica apenas un 6 % de la variación. Las franjas horizontales en 0 y 1 de la figura 4 corresponden a las acumulaciones ya comentadas.

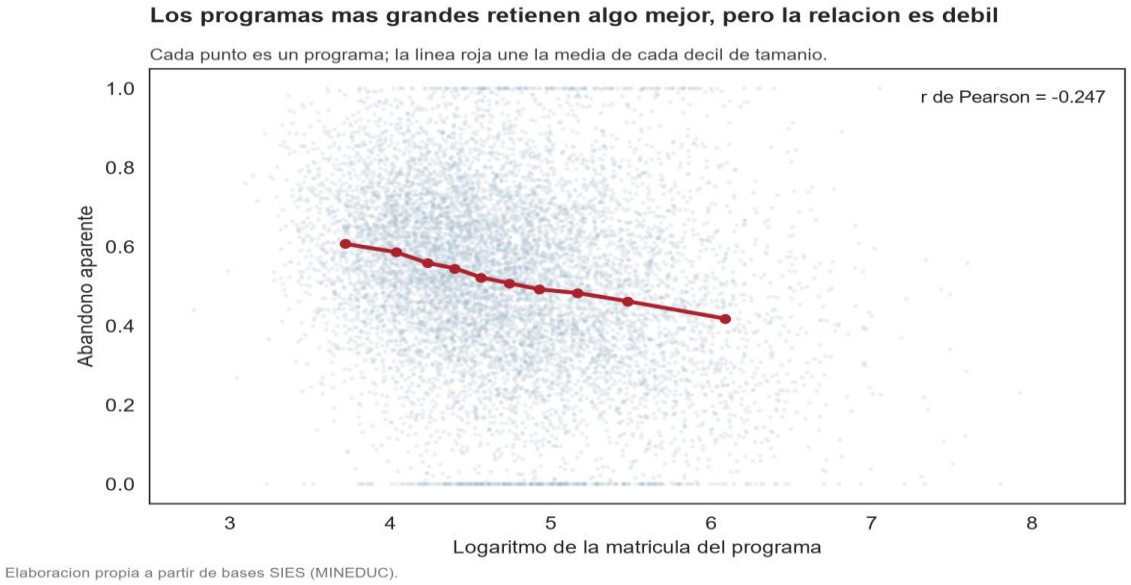


Figura 4. Abandono frente al tamaño del programa; la línea roja une la media de cada decil.

4. Estimación puntual e intervalos de confianza

4.1 Sobre qué población se infiere

Antes de calcular un intervalo conviene responder una pregunta que suele saltarse: **¿de qué población se habla?** Los 9.678 programas no son una muestra extraída al azar de un universo mayor: son todos los programas chilenos que cumplen los criterios de inclusión en el período. Sobre un censo, un intervalo de confianza en sentido estricto carecería de sentido, porque el parámetro ya está medido sin error muestral.

La inferencia que sigue se formula, por tanto, sobre el **proceso generador**: los programas observados se tratan como una realización de un sistema educativo que sigue operando y que pudo haber producido resultados algo distintos. El parámetro estimado es el abandono esperado de ese proceso, y el intervalo mide la incertidumbre que introduce la variabilidad del sistema, no el muestreo. La distinción cambia lo que puede afirmarse: autoriza a decir que el abandono esperado está entre 0,514 y 0,523, y prohíbe decir que hay un 95 % de probabilidad de que el valor real caiga ahí, que es una lectura que el intervalo frecuentista no admite.

4.2 Tres parámetros estimados

Se estiman tres parámetros de naturaleza distinta, cada uno con el procedimiento que le corresponde:

Parámetro	Estimación puntual	IC 95 %	Procedimiento
Abandono esperado del sistema	0,5183	[0,5138 ; 0,5227]	t de Student, gl = 9.677
Programas con abandono > 50 %	0,5494	[0,5395 ; 0,5593]	Wilson (proporción)
Diferencia por acreditación	+0,1757	[0,1590 ; 0,1924]	Welch, gl = 902

La media. El intervalo mide nueve milésimas de ancho. Esa precisión no proviene de que el fenómeno sea homogéneo —la desviación estándar de 0,224 dice lo contrario— sino del tamaño del conjunto: el error estándar divide la desviación por la raíz de 9.678, es decir por 98,4. Conviene no confundir precisión con homogeneidad: el intervalo

describe cuán bien conocemos el promedio, no cuán parecidos son los programas entre sí. Un remuestreo bootstrap de 5.000 réplicas arroja [0,5139 ; 0,5226], coincidente hasta la cuarta cifra, lo que confirma que el supuesto de normalidad de la media es sostenible.

La proporción. Se emplea el método de Wilson (1927) en lugar de la aproximación normal porque no produce límites fuera del intervalo [0, 1] y conserva su cobertura cerca de los extremos. Con una proporción próxima a 0,5 y un *n* grande ambos coinciden, pero la elección deja de ser indiferente en otros escenarios.

La diferencia. El intervalo no contiene el cero y su límite inferior ya alcanza los 15,9 puntos porcentuales, de modo que la conclusión no depende del extremo del intervalo que se tome.

5. Pruebas de hipótesis y tamaño del efecto

El procedimiento adecuado depende del tipo de las variables implicadas, no de la costumbre. Se aplican tres contrastes distintos, uno por cada combinación presente en los datos, todos al nivel **$\alpha = 0{,}05$** fijado antes de examinar los resultados.

Respecto de los supuestos: la prueba de Kolmogorov-Smirnov rechaza la normalidad exacta ($D = 0{,}021$; $p < 0{,}001$), pero con $n = 9.678$ detecta desviaciones irrelevantes. Lo que los procedimientos requieren no es que la variable sea normal, sino que lo sea la distribución de la media, que el teorema central del límite garantiza a este tamaño y que la asimetría casi nula refuerza. La prueba de Levene no rechaza la igualdad de varianzas ($W = 0{,}869$; $p = 0{,}351$); aun así se emplea la versión de Welch (1947), que no la supone, por ser la opción conservadora.

Contraste	Hipótesis nula	Estadístico	Valor p	Tamaño del efecto
t de Welch	Igual abandono según acreditación	$t = 20{,}61$ (gl = 902)	$1{,}2 \times 10^{-77}$	d de Cohen = 0,80 — grande
ANOVA de un factor	Igual abandono en las 10 áreas	$F = 44{,}30$ (gl = 9; 9.668)	$1{,}2 \times 10^{-78}$	$\eta^2 = 0{,}040$ — pequeño
Chi-cuadrado	Independencia institución / abandono	$\chi^2 = 102{,}51$ (gl = 5)	$1{,}6 \times 10^{-20}$	V de Cramér = 0,103 — débil

Los tres rechazan la hipótesis nula y, sin embargo, solo uno orienta la decisión. Esta es la conclusión metodológica central del informe.

Los programas de instituciones nunca acreditadas presentan un abandono 17,6 puntos porcentuales mayor, con una **d de Cohen de 0,80** que la convención establecida por Cohen (1988) sitúa en el umbral de los efectos grandes: la acreditación no solo distingue grupos de forma detectable, sino de forma sustantiva. El área del conocimiento, en cambio, explica apenas el **4 % de la varianza** del abandono, y el tipo de institución arroja una asociación que la V de Cramér (1946) califica de débil, coherente con el solapamiento que ya mostraba la figura 2.

Con 9.678 observaciones la potencia es tan alta que **el valor p pierde casi toda capacidad de discriminar**: los tres contrastes arrojan valores entre 10^{-20} y 10^{-78}, y aun así sus efectos van de grande a despreciable. Informar solo la significación llevaría a tratar los tres resultados como equivalentes, que es exactamente el error que una decisión de focalización no puede permitirse. La advertencia es la misma que formula la American Statistical Association al recordar que un valor p, por sí solo, no mide la magnitud de un efecto ni su relevancia práctica (Wasserstein y Lazar, 2016).

Las comparaciones múltiples de Tukey (1949), que controlan el error por familia, confirman diferencias significativas en 30 de los 45 pares de áreas; la mayor separa Humanidades de Salud, con 17,4 puntos porcentuales.

6. Interpretación preliminar

Para la autoridad que debe repartir un presupuesto limitado de retención, los resultados se traducen en cuatro afirmaciones.

La magnitud justifica actuar. El abandono esperado del sistema se estima en 0,518, con un intervalo de 0,514 a 0,523, y el 54,9 % de los programas supera el 50 %. No se trata de casos aislados.

La heterogeneidad justifica focalizar. Con un coeficiente de variación de 0,43 y una mitad central que abarca casi treinta puntos porcentuales, los programas difieren demasiado como para tratarlos igual.

El criterio de focalización importa, y no todos valen. La acreditación institucional separa grupos con una diferencia de 17,6 puntos y un efecto grande: es un criterio útil. El área del conocimiento y el tipo de institución producen contrastes igual de significativos pero con efectos pequeños, porque la mayor parte de la variación ocurre dentro de cada categoría y no entre ellas; usarlos como criterio principal repartiría recursos con poca ganancia.

La incertidumbre acompaña, pero no impide decidir. Los intervalos son estrechos y ninguna de las conclusiones anteriores cambia según el extremo del intervalo que se adopte.

La recomendación preliminar, por tanto, no es focalizar por categorías administrativas sino por el **nivel de abandono medido en cada programa**, empleando la acreditación como señal complementaria. Las categorías agregadas resultan demasiado gruesas para capturar dónde está realmente el problema.

7. Limitaciones

El abandono es aparente, no observado: quien se cambia de carrera y se titula en otra parte cuenta como abandono, de modo que la magnitud estimada es una cota superior. **La unidad de análisis es el programa**, por lo que las conclusiones no pueden trasladarse a individuos sin incurrir en falacia ecológica. **Las asociaciones no son causas**: no hay grupo de control ni asignación aleatoria, y la acreditación podría estar recogiendo el efecto de la selectividad del ingreso o de los recursos de la institución. **La ventana temporal trunca las cohortes recientes**, cuyo abandono aparente queda inflado. Y **los contrastes son univariados**, de modo que los efectos podrían estar confundidos entre sí; un modelo multivariado, previsto para la fase siguiente, permitiría estimar cada efecto manteniendo los demás constantes.

8. Reproducibilidad

Todas las cifras, tablas y figuras de este informe se generan al ejecutar el cuaderno `notebooks/Sumativa1_Analisis_Desercion.ipynb`, que corre de principio a fin sin errores y deja sus salidas en `resultados/`. El conjunto analítico está versionado en el repositorio, de modo que la reproducción no requiere descargar las bases originales del SIES. Las versiones de las bibliotecas están fijadas en `requirements.txt` y la semilla aleatoria en 42.

Repositorio: https://github.com/santunez75/analisis-desercion

9. Referencias

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Cramér, H. (1946). *Mathematical methods of statistics*. Princeton University Press.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D. et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.

McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61).

Seabold, S. y Perktold, J. (2010). statsmodels: econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96).

Servicio de Información de Educación Superior. (2026). *Bases de datos de matrícula en educación superior 2007–2026*. Ministerio de Educación de Chile. https://datosabiertos.mineduc.cl/

Servicio de Información de Educación Superior. (2026). *Bases de datos de titulados de educación superior 2007–2025*. Ministerio de Educación de Chile. https://datosabiertos.mineduc.cl/

Tukey, J. W. (1949). Comparing individual means in the analysis of variance. *Biometrics*, 5(2), 99–114.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D. et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA statement on p-values: context, process, and purpose. *The American Statistician*, 70(2), 129–133.

Welch, B. L. (1947). The generalization of «Student's» problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212.