MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, simulación y métodos de remuestreo

Título del proyecto

Análisis de la deserción en la educación superior chilena

Integrantes

María Fassler Neumann · Sebastian Antunez Noguera — Grupo 4

Conjunto de datos

SIES: matrícula 2007–2026 y titulados 2007–2025 (Mineduc, datos abiertos)

Docente

Jean Paul Maidana

Fecha

13 de octubre de 2026

Repositorio GitHub

https://github.com/santunez75/analisis-desercion

Santiago, Chile

Conexión con evaluaciones anteriores

Todo el trabajo se construye sobre los resultados propios de la Sumativa 1, donde las tres medias estimadas y la proporción de programas sobre el umbral, con sus intervalos clásicos. La prueba t de Welch sobre la acreditación institucional y las correlaciones del análisis bivariado. Cada apartado valida o pone a prueba uno de esos resultados, y la simulación del apartado 4 emplea parámetros estimados allí.

El conjunto analítico reúne 9.678 programas de pregrado, construidos a partir de las bases abiertas del SIES. La unidad de análisis es el programa y la variable respuesta es el abandono aparente, definido como el complemento de la razón entre titulados e ingreso de la cohorte correspondiente.

Índice

1. Validación de resultados de S1 mediante bootstrap 3

2. Validación de pruebas de hipótesis mediante permutación 3

3. Evaluación de estabilidad de correlaciones 4

4. Simulación Monte Carlo basada en parámetros de S1 5

5. Análisis de robustez. 6

6. Preparación para la Sumativa 3 6

6.1 Reproducibilidad 7

7. Bibliografía 7

1. Validación de resultados de S1 mediante bootstrap

Aplicamos bootstrap no paramétrico (Efron y Tibshirani, 1993) con 10.000 remuestras a cuatro parámetros de la sumativa 1. Las tres medias estimadas que son abandono, tiempo de matrícula y proporción de mujeres, más la proporción de programas que superan el umbral del 50 %, cuyo intervalo se había construido con el método de Wilson. Para cada uno calculamos el intervalo percentil y el BCa, que corrige el sesgo y aceleración (Efron, 1987) y los comparamos con el clásico de S1.

Los tres métodos descansan en supuestos distintos, el clásico asume que la distribución de la media muestral es aproximadamente normal, el percentil supone que la distribución bootstrap está centrada y es simétrica, y el BCa relaja ese supuesto corrigiendo el sesgo (z_0) y la asimetría (a).

Parámetro	Clásico (S1)	Percentil	BCa	Discrep.
Abandono medio	[0,5138; 0,5227]	[0,5139; 0,5228]	[0,5138; 0,5227]	+0,41 %
Edad media de los estudiantes	[24,091; 24,230]	[24,091; 24,230]	[24,092; 24,230]	−0,75 %
Proporción de mujeres	[0,5097; 0,5215]	[0,5097; 0,5215]	[0,5097; 0,5215]	−0,59 %
Programas sobre el 50 %	[0,5395; 0,5593]	[0,5396; 0,5591]	[0,5396; 0,5591]	−0,86 %

Tabla 1: Intervalos de confianza al 95 %: clásico de S1, percentil y BCa.

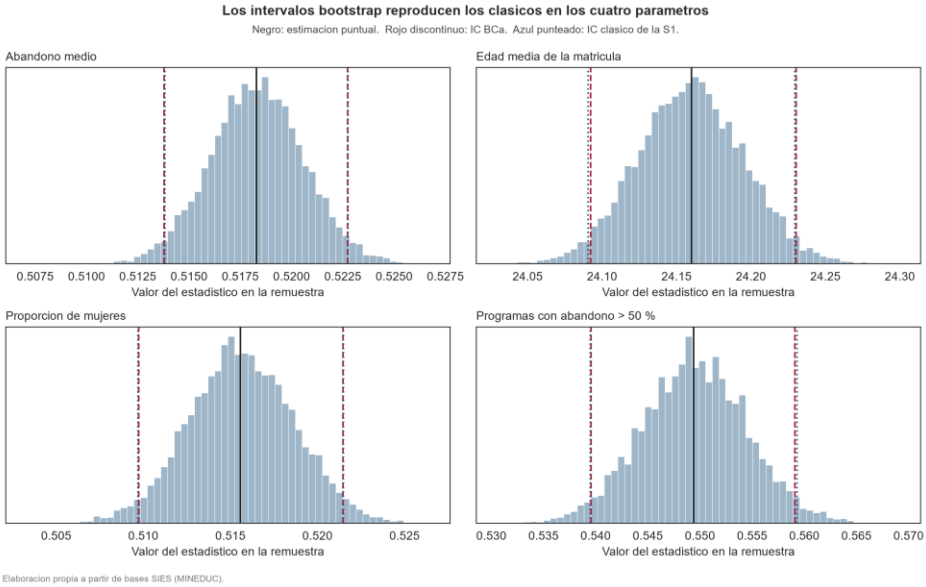


Figura 1: Distribuciones bootstrap de los cuatro parámetros (10.000 remuestras). La línea negra marca la estimación puntual, la roja discontinua el IC BCa y la azul punteada el IC clásico de S1.

Los factores de corrección son próximos a cero en los cuatro casos, donde z_0 varía entre −0,015 y +0,017, y a entre −0,0003 y +0,0020. En consecuencia, el BCa apenas se desplaza respecto del percentil, como máximo 0,0016 en la edad de los estudiantes y los tres intervalos se superponen, con discrepancias de amplitud inferiores al 0,9 %. Que el percentil y BCa coincidan indica además que los estimadores son no sesgados en la práctica y que su distribución no está torcida.

Significa que el supuesto que la Sumativa 1 invocó sin comprobar se sostiene con las 9.678 observaciones. La distribución bootstrap de cada media resulta simétrica y campaniforme pese a que la variable de origen no lo sea, y el estimador no presenta sesgo apreciable. Cuando la variable es asimétrica o la cola es larga, z_0 y “a” crecen y el BCa se vuelve el más confiable. Aquí los tres coinciden y el clásico basto.

El bootstrap valida la precisión con que se estima el promedio, no la construcción de la variable. Si el abandono aparente sobreestima el abandono real, y la Sumativa 1 argumentó que lo hace, el bootstrap reproducirá fielmente ese sesgo, porque remuestrea los mismos datos que lo contienen.

2. Validación de pruebas de hipótesis mediante permutación

Validamos la t de Welch sobre la acreditación institucional, que en S1 comparó el abandono de los programas de instituciones nunca acreditadas (n = 757) con el de las siempre acreditadas (n = 7.672). Es el contraste que más pesa en las conclusiones pues fue el único con tamaño del efecto grande (d = 0,80) y el que sostiene la recomendación de focalización.

Si la acreditación fuese irrelevante, las etiquetas de grupo serían intercambiables. El test de permutación (Good, 2005) reasigna esas etiquetas al azar 10.000 veces y construye así la distribución del estadístico bajo la hipótesis nula, sin suponer normalidad ni aproximar grados de libertad.

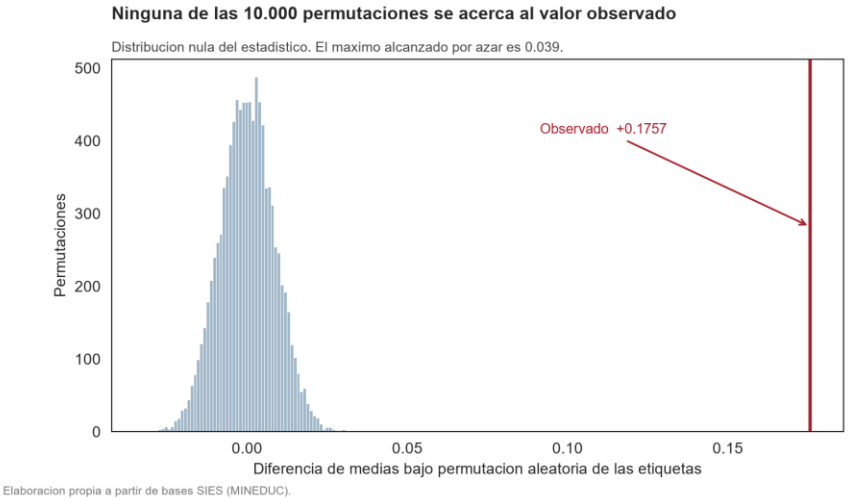


Figura 2: Distribución de la diferencia de medias bajo la hipótesis nula (10.000 permutaciones). El valor observado queda fuera del rango generado por el azar.

La diferencia observada es de +0,1757, mientras que la distribución nula se concentra en cero con una desviación típica de 0,0085 y un máximo absoluto de 0,0386. Ninguna de las 10.000 permutaciones se acerca al valor observado, de modo que el valor p de permutación es 0,0002, el mínimo que el procedimiento puede devolver en un contraste bilateral. La distancia es de más de veinte desviaciones típicas de la distribución nula.

Coincide con el resultado paramétrico de S1 en la decisión, pero ambos valores no son comparables en magnitud. El paramétrico, de $1{,}2 \times 10^{-77}$, extrapola a la cola de una distribución teórica y aparenta una precisión que no tiene, porque ninguna observación respalda esa región. El de permutación solo afirma lo que observó. Para este caso resulta más apropiado, por dos razones, no exige supuestos distribucionales y los grupos son muy desiguales en tamaño, situación en que las aproximaciones asintóticas se comportan peor.

3. Evaluación de estabilidad de correlaciones

Evaluamos cinco correlaciones de S1 con intervalos bootstrap al 95 %, remuestreando pares completos de observaciones para preservar la dependencia entre las dos variables. En S1 las nueve correlaciones reportadas resultaron significativas al 5 % por efecto del tamaño muestral, la significación, sin embargo, no informa sobre la estabilidad.

Variable	r	IC bootstrap 95 %	Amplitud/|r|	Estado
Acreditación de la carrera	−0,311	[−0,329; −0,293]	0,12	Robusta
Acreditación de la institución	−0,259	[−0,278; −0,240]	0,15	Robusta
Tamaño del programa (log)	−0,247	[−0,267; −0,228]	0,16	Robusta
Proporción de mujeres	−0,165	[−0,184; −0,145]	0,24	Robusta
Egreso de enseñanza municipal	+0,050	[+0,031; +0,070]	0,79	Débil

Tabla 2: Estabilidad de cinco correlaciones de S1 según su intervalo bootstrap.

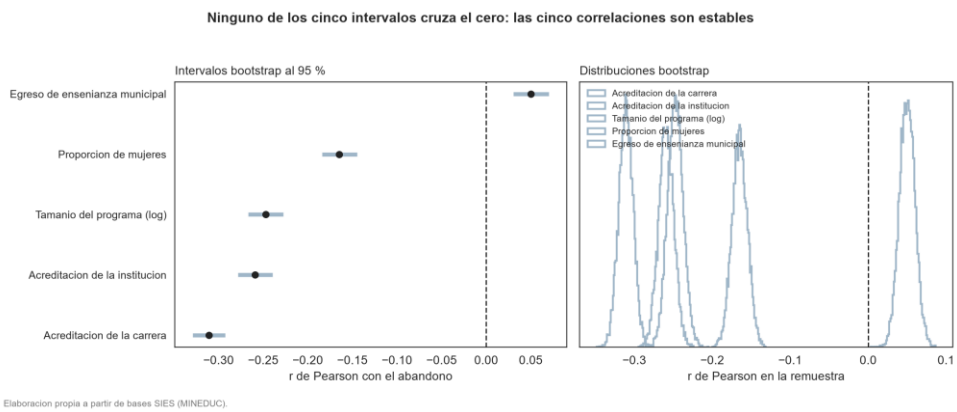


Figura 3: Intervalos bootstrap al 95 % de las cinco correlaciones y sus distribuciones completas. Ninguna cruza el cero.

Ningún intervalo incluye el cero, de modo que el signo de las cinco está determinado por los datos y no por el azar del muestreo. Pero estabilidad y relevancia son cosas distintas, las tres correlaciones fuertes tienen intervalos estrechos frente a su propia magnitud, mientras que la del egreso municipal vale apenas +0,050 y su intervalo ocupa cuatro quintas partes de ese valor. Es estadísticamente distinta de cero y prácticamente irrelevante, exactamente la situación que S1 anticipó al advertir que con 9.678 observaciones todo resulta significativo.

4. Simulación Monte Carlo basada en parámetros de S1

S1 terminó con una recomendación que no pudo cuantificar “Focalizar por el nivel de abandono medido en cada programa y no por categorías administrativas”. La simulación (Robert y Casella, 2004) responde esa pregunta en los términos en que una autoridad la formularía, si solo puedo intervenir en una fracción de los programas, ¿cuántos estudiantes más alcanzo eligiéndolos por su abandono observado en lugar de por la acreditación de su institución?

Simulamos 10.000 sistemas de 8.429 programas, los de estado de acreditación inequívoco, con parámetros exclusivamente de S1, abandono medio 0,6636 (DE 0,2243) en los de instituciones nunca acreditadas y 0,4879 (DE 0,2178) en los acreditados, con una proporción del 9 % de los primeros, y la distribución empírica del ingreso. Sobre cada sistema comparamos dos estrategias con el mismo presupuesto, el 10 % de los programas. La A prioriza los de instituciones no acreditadas, la B elige los de mayor abandono. El modelo supone que la intervención recupera una fracción ε de quienes habrían abandonado, de modo que intervenir rinde más donde el abandono es mayor ε es un supuesto de política y no un parámetro estimado, y el apartado 5 muestra que la comparación es independiente de él.

Estrategia	Media	DE	Percentil 2,5	Percentil 97,5
A — por acreditación	21.742	854	20.137	23.445
B — por abandono observado	30.205	1.061	28.204	32.356
Ventaja de B	8.462	1.096	6.306	10.647

Tabla 3: Estudiantes retenidos por el programa de retención en 10.000 simulaciones.

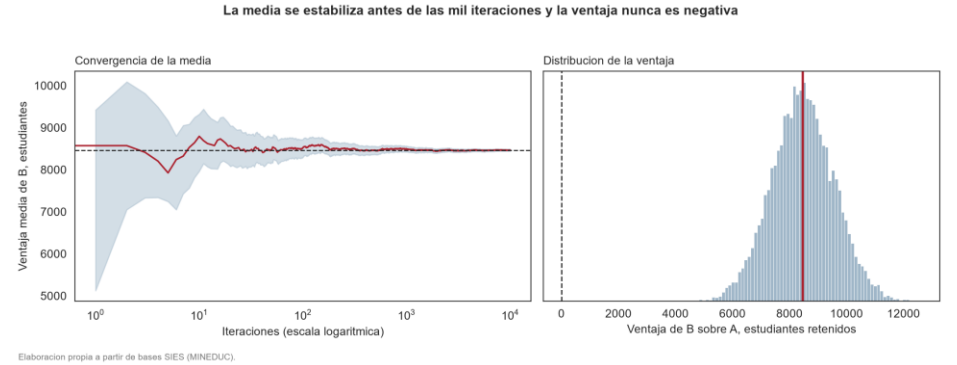


Figura 4: (a) Convergencia de la ventaja media de la estrategia B. (b) Distribución de esa ventaja en las 10.000 iteraciones.

Focalizar por el abandono observado alcanza a un 38,9 % más de estudiantes, con una diferencia media de 8.462. La estrategia B supera a la A en las 10.000 iteraciones y el percentil 2,5 de la ventaja, 6.306 estudiantes, queda muy lejos del cero.

La media converge antes de las mil iteraciones y el error estándar de Monte Carlo al final del recorrido es de 11 estudiantes, un 0,25 % de la magnitud estimada; bastarían 644 iteraciones para una precisión del 1 %. Verificar convergencia permite separar la incertidumbre del fenómeno, que es grande, de la que introduce el método, que aquí es despreciable.

Para la gestión, el resultado cuantifica la recomendación que S1 dejó enunciada: que la acreditación distinga grupos con un efecto grande no la convierte en buen criterio de focalización, porque los programas de instituciones no acreditadas son demasiado pocos para absorber el presupuesto y la mayor parte de los programas con abandono alto queda fuera de esa categoría.

5. Análisis de robustez.

El jackknife sobre los 9.678 programas arroja un error estándar de 0,002276, idéntico al clásico e igual al bootstrap hasta la quinta cifra, y un sesgo estimado nulo. Ninguna observación individual desplaza la media más de $5{,}4 \times 10^{-5}$: no hay programas influyentes, a diferencia de lo que ocurre con variables de cola larga.

La exclusión de los 465 programas censurados en 0 y en 1, identificados en S1, desplaza la media del abandono de 0,518 a 0,527 y reduce su desviación típica de 0,224 a 0,199. La correlación con la acreditación de carrera apenas se mueve, de −0,311 a −0,310, y el contraste de Welch mantiene su decisión. Son cambios pequeños, pero recuerdan que la censura de la variable no es inocua.

Sobre la simulación, la comparación entre estrategias es algebraicamente independiente de ε, porque ese factor multiplica por igual a ambas y se cancela en el cociente. La conclusión no descansa sobre el supuesto que peor se conoce. Los ejes que sí podrían moverla son el presupuesto y la proporción de instituciones no acreditadas.

Ventaja relativa de B (%)	5 %	10 %	15 %	20 %
No acreditados 9 % (valor de S1)	+44,1	+38,8	+43,6	+44,1
No acreditados 20 %	+47,0	+38,9	+32,7	+27,8
No acreditados 35 %	+49,9	+42,7	+36,8	+32,0
No acreditados 50 %	+51,3	+45,6	+40,1	+35,6

Tabla 4: Ventaja de la estrategia B según el presupuesto (columnas) y la proporción de programas no acreditados (filas).

La ventaja se mantiene entre el 28 y el 51 % en los dieciséis escenarios. Ni multiplicando por cinco la proporción de programas no acreditados la estrategia por acreditación llega a competir. Sustituir además la distribución generadora, de normal truncada a Beta ajustada por momentos a las mismas medias y desviaciones, reduce la ventaja de 8.462 a 7.958 estudiantes un 6 % y B sigue ganando en el 100 % de las iteraciones. El resultado no es un artefacto de la forma supuesta.

En síntesis, son confiables las cuatro estimaciones puntuales con sus intervalos, el contraste sobre la acreditación, las tres correlaciones fuertes y la ventaja de focalizar por abandono. Requieren cautela la media del abandono frente a la censura de la variable y la correlación con el egreso municipal, cuyo signo está definido pero cuya magnitud es irrelevante. Y todo lo anterior valida el procedimiento, no el dato, ningún método de remuestreo corrige un sesgo de construcción, porque remuestrea los mismos datos que lo contienen.

6. Preparación para la Sumativa 3

El archivo resultados_validados.csv, en la raíz del repositorio, recoge en forma legible por máquina el veredicto de cada resultado, con sus intervalos clásico y bootstrap. La Tabla 5 lo resume.

Resultado de S1	Validación en S2	Estado
Cuatro medias y proporciones	Clásico, percentil y BCa coinciden; z_0 y a nulos	Robusto
Diferencia por acreditación (Welch)	Permutación da el mismo veredicto sin supuestos	Robusto
Tres correlaciones fuertes	IC bootstrap estrechos, no cruzan el cero	Robusto
Correlación con egreso municipal	Signo definido, amplitud del 79 % de su magnitud	Cautela
Recomendación de focalización	Monte Carlo la cuantifica en +38,9 %	Robusto
465 programas censurados en 0 y 1	Desplazan la media 0,009 al excluirlos	Cautela

Tabla 5: Reporte de resultados validados para la Sumativa 3.

Recomendaciones metodológicas para S3.

- Reportar los intervalos BCa en lugar de los clásicos: coinciden, de modo que no hay costo, y no dependen de supuestos.
- Construir el modelo multivariado sobre las tres correlaciones estables y fuertes, dejando las débiles como controles sin interpretación propia.
- Agrupar los errores estándar por institución, porque los programas de una misma institución no son observaciones independientes.
- Conservar los 465 programas censurados y declarar su efecto en lugar de excluirlos. Y declarar siempre como supuesto de política, no como estimación, cualquier parámetro de eficacia de una intervención.

6.1 Reproducibilidad

Todas las cifras de este informe se generan al ejecutar S2/Sumativa2_Validacion_Remuestreo.ipynb, que corre de principio a fin sin errores en poco más de un minuto y deja sus salidas en S2/resultados/. Cada procedimiento emplea 10.000 repeticiones y la semilla fijada en 42, de modo que los resultados son reproducibles hasta la última cifra. El repositorio contiene las carpetas S1 y S2 con los entregables de cada fase, el conjunto analítico versionado y los scripts que lo construyeron a partir de las bases del SIES.

7. Bibliografía

Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association, 82*(397), 171–185.

Efron, B. y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.ª ed.). Springer.

Robert, C. P. y Casella, G. (2004). *Monte Carlo statistical methods* (2.ª ed.). Springer.

Servicio de Información de Educación Superior. (2026). *Bases de matrícula 2007–2026 y titulados 2007–2025* [Conjunto de datos]. Ministerio de Educación de Chile. https://datosabiertos.mineduc.cl/

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D. et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272.