Facultad de Ingeniería
Magíster en Ciencia de Datos e Inteligencia Artificial

VALIDACIÓN POR REMUESTREO Y SIMULACIÓN DEL ANÁLISIS DE DESERCIÓN

Informe técnico de validación

Evaluación Sumativa 2
Estadística Computacional

Autores:
María Fassler Neumann / Sebastian Antunez Noguera
Grupo 4

Profesor:
Jean Paul Maidana

Santiago, Chile
2026

Índice

1. Qué se valida y por qué 3
2. Validación bootstrap de los intervalos de confianza 3
3. Validación de una prueba de hipótesis por permutación 4
4. Estabilidad de las correlaciones 5
5. Simulación Monte Carlo de la decisión de focalización 5
6. Análisis de robustez y sensibilidad 6
6.1 Observaciones influyentes y valores extremos 6
6.2 Sensibilidad de la simulación a sus variables de entrada 7
7. Resultados validados para la Sumativa 3 7
8. Reproducibilidad 8

1. Qué se valida y por qué

La Sumativa 1 estimó parámetros y contrastó hipótesis sobre 9.678 programas de educación superior apoyándose en supuestos que no verificó: normalidad de la media muestral, varianzas comparables entre grupos, validez de las aproximaciones asintóticas. Esos supuestos se justificaron invocando el teorema central del límite, lo cual es razonable con ese tamaño, pero razonable no es lo mismo que comprobado.

Este informe somete aquellos resultados a **métodos que no dependen de tales supuestos**. El bootstrap estima la distribución de un estadístico remuestreando los propios datos en lugar de postular una forma teórica; el test de permutación construye la distribución nula reasignando las etiquetas de grupo; la simulación Monte Carlo traduce los parámetros estimados a consecuencias para la decisión que motivó el estudio. Todos los procedimientos emplean **B = 10.000** repeticiones y semilla fija, de modo que son reproducibles.

La pregunta que organiza el trabajo no es si los resultados anteriores se repiten, sino **cuáles de ellos resisten** y con qué grado de confianza puede apoyarse en ellos la fase siguiente.

2. Validación bootstrap de los intervalos de confianza

Se validan cuatro parámetros: las tres medias estimadas en la fase anterior y la proporción de programas que superan el umbral del 50 %, cuyo intervalo se había construido por el método de Wilson. Para cada uno se calculan dos intervalos bootstrap. El **percentil** toma los cuantiles 2,5 y 97,5 de las 10.000 réplicas. El **BCa** corrige además el sesgo del estimador y la asimetría de su distribución, estimada por jackknife; cuando ambas correcciones son nulas coincide con el percentil, y cuando difieren es el percentil el que está equivocado.

Parámetro	Estimación	IC clásico (S1)	IC percentil	IC BCa	Discrepancia
Abandono medio	0,5183	[0,5138 ; 0,5227]	[0,5139 ; 0,5228]	[0,5138 ; 0,5227]	+0,41 %
Edad media de la matrícula	24,160	[24,091 ; 24,230]	[24,091 ; 24,230]	[24,092 ; 24,230]	−0,75 %
Proporción de mujeres	0,5156	[0,5097 ; 0,5215]	[0,5097 ; 0,5215]	[0,5097 ; 0,5215]	−0,59 %
Programas con abandono > 50 %	0,5494	[0,5395 ; 0,5593]	[0,5396 ; 0,5591]	[0,5396 ; 0,5591]	−0,86 %

Los cuatro intervalos bootstrap reproducen los clásicos hasta la tercera o cuarta cifra decimal. La discrepancia de amplitud no supera el 0,9 % en ningún caso. Ese acuerdo significa que el supuesto que la Sumativa 1 invocó sin comprobar se sostiene: con 9.678 observaciones la distribución bootstrap de cada media resulta simétrica y campaniforme pese a que la variable de origen no lo sea.

La coincidencia entre **percentil y BCa** añade una segunda conclusión: las correcciones de sesgo y aceleración son prácticamente nulas, de modo que los estimadores son insesgados en la práctica y su distribución no está torcida. No hace falta elegir entre ambos métodos porque dicen lo mismo.

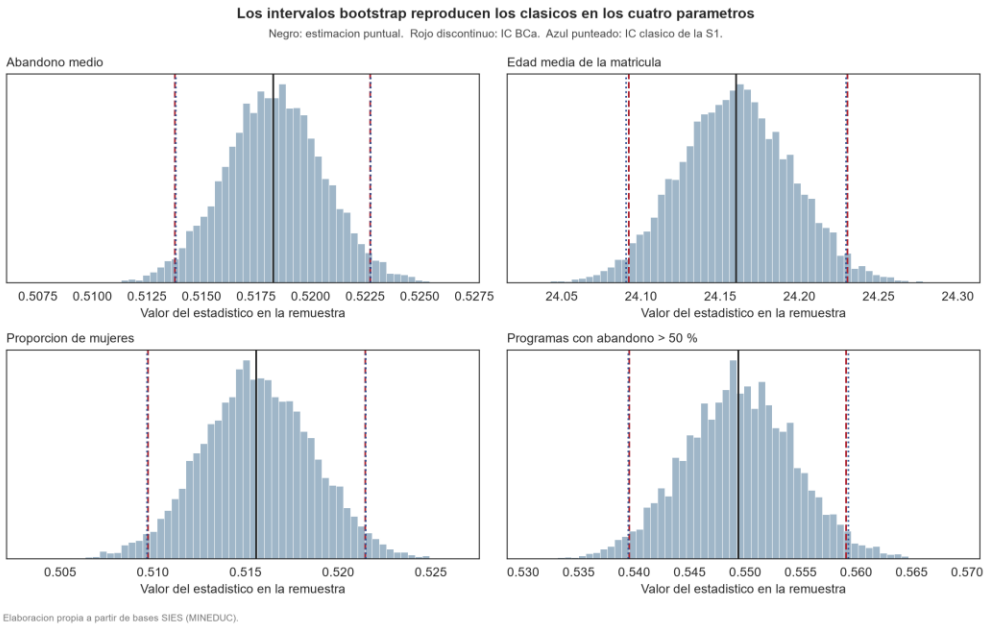


Figura 1. Distribuciones bootstrap de los cuatro parámetros. Negro: estimación puntual. Rojo discontinuo: IC BCa. Azul punteado: IC clásico de la Sumativa 1.

El bootstrap valida la precisión con que se estima el promedio, no la representatividad del dato ni la construcción de la variable. Si el abandono aparente sobreestima el abandono real —y la Sumativa 1 argumentó que lo hace—, el bootstrap reproducirá fielmente ese sesgo, porque remuestrea los mismos datos que lo contienen.

3. Validación de una prueba de hipótesis por permutación

De los cinco contrastes de la fase anterior se valida la **t de Welch sobre la acreditación institucional**, que comparó el abandono de los programas de instituciones nunca acreditadas (n = 757) con el de las siempre acreditadas (n = 7.672). Es el que más pesa en las conclusiones: fue el único con tamaño del efecto grande (d = 0,80) y el que sostiene la recomendación de focalización.

El test de permutación no supone normalidad ni aproxima grados de libertad. Si la acreditación fuese irrelevante, las etiquetas de grupo serían intercambiables; basta reasignarlas al azar 10.000 veces para construir la distribución del estadístico bajo esa hipótesis.

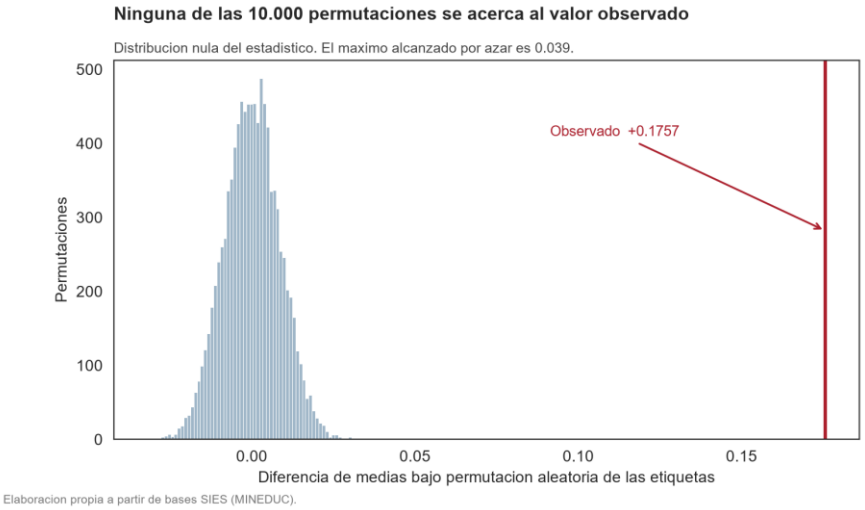


Figura 2. Distribución nula de la diferencia de medias bajo permutación aleatoria de las etiquetas, frente al valor observado.

Ninguna de las 10.000 permutaciones se acercó al valor observado. El mayor valor alcanzado por azar fue 0,0386, frente a una diferencia observada de 0,1757: más de veinte desviaciones típicas de la distribución nula, que vale 0,0085. El valor p de permutación es 0,0002, el mínimo que el procedimiento puede devolver en un contraste bilateral con ese número de repeticiones.

La comparación con el valor p paramétrico de la Sumativa 1, de $1{,}2 \times 10^{-77}$, ilustra una diferencia conceptual que conviene no pasar por alto. **Ambos coinciden en la decisión y no son comparables en magnitud.** El paramétrico extrapola a la cola de una distribución teórica y puede producir cifras arbitrariamente pequeñas; el de permutación solo afirma lo que observó. El primero aparenta una precisión que no tiene, porque un valor de 10^{-77} descansa íntegramente en la forma supuesta de una región donde ningún dato lo respalda.

Para este caso resulta más apropiado el de permutación, por dos razones: no exige supuestos distribucionales y los grupos son muy desiguales en tamaño, situación en que las aproximaciones asintóticas se comportan peor. Su conclusión es más modesta y más defendible.

4. Estabilidad de las correlaciones

La Sumativa 1 reportó nueve correlaciones con el abandono, todas significativas al 5 % por efecto del tamaño muestral. La significación, sin embargo, no informa sobre la estabilidad. Se seleccionan cinco que cubren todo el rango observado y se construye para cada una un intervalo bootstrap al 95 %, remuestreando **pares completos de observaciones** para preservar la dependencia entre las dos variables.

Variable	r	IC bootstrap 95 %	Amplitud / |r|	Veredicto
Acreditación de la carrera	−0,311	[−0,329 ; −0,293]	0,12	Robusta
Acreditación de la institución	−0,259	[−0,278 ; −0,240]	0,15	Robusta
Tamaño del programa (log)	−0,247	[−0,267 ; −0,228]	0,16	Robusta
Proporción de mujeres	−0,165	[−0,184 ; −0,145]	0,24	Robusta
Egreso de enseñanza municipal	+0,050	[+0,031 ; +0,070]	0,79	Débil, signo definido

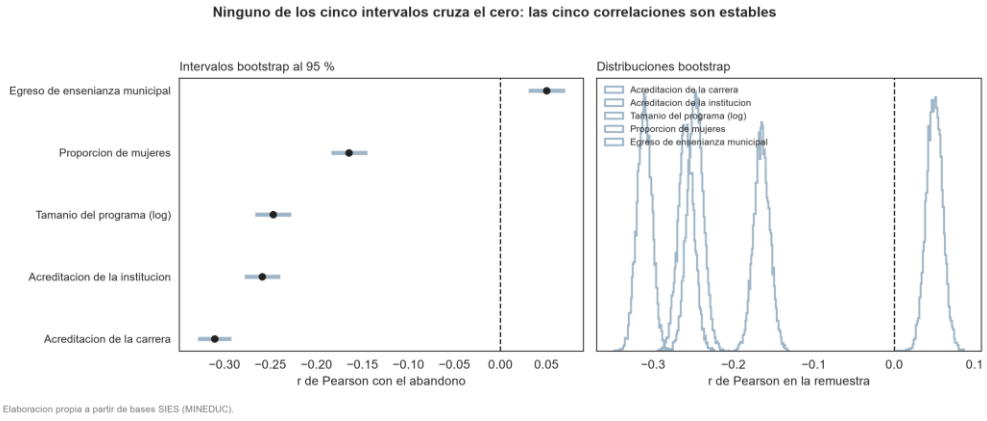


Figura 3. Intervalos bootstrap al 95 % de las cinco correlaciones y sus distribuciones completas.

Ningún intervalo incluye el cero, de modo que el signo de las cinco correlaciones está determinado por los datos y no por el azar del muestreo. Pero estabilidad y relevancia son cosas distintas, y el criterio de amplitud relativa las separa: las tres correlaciones fuertes tienen intervalos estrechos frente a su propia magnitud, mientras que la del egreso municipal vale apenas +0,050 y su intervalo ocupa cuatro quintas partes de ese valor. Es **estadísticamente distinta de cero y prácticamente irrelevante**, exactamente la situación que la fase anterior anticipó.

5. Simulación Monte Carlo de la decisión de focalización

La Sumativa 1 terminó con una recomendación que no pudo cuantificar: focalizar por el **nivel de abandono medido en cada programa** y no por categorías administrativas. La simulación responde esa pregunta en los términos en que una autoridad la formularía: **si solo puedo intervenir en una fracción de los programas, ¿cuántos estudiantes más alcanzo eligiéndolos por su abandono observado en lugar de por la acreditación de su institución?**

Se simulan 10.000 sistemas de 8.429 programas —aquellos cuyo estado de acreditación es inequívoco— con los parámetros estimados en la fase anterior: abandono medio de 0,6636 (DE 0,2243) en los programas de instituciones nunca acreditadas y de 0,4879 (DE 0,2178) en los de siempre acreditadas, una proporción del 9 % de los primeros, y la distribución empírica del ingreso. Sobre cada sistema se comparan dos estrategias con el mismo presupuesto, el 10 % de los programas: la **A** prioriza los de instituciones no acreditadas; la **B** elige los de mayor abandono.

El modelo supone que la intervención **recupera una fracción ε de quienes habrían abandonado**, de modo que intervenir rinde más donde el abandono es mayor. El valor de ε no es un parámetro estimado sino una decisión de política —el conjunto no contiene información sobre la eficacia de ningún programa de retención— y se adopta un 10 % como escenario base; el apartado 6 muestra que la comparación entre estrategias es independiente de él.

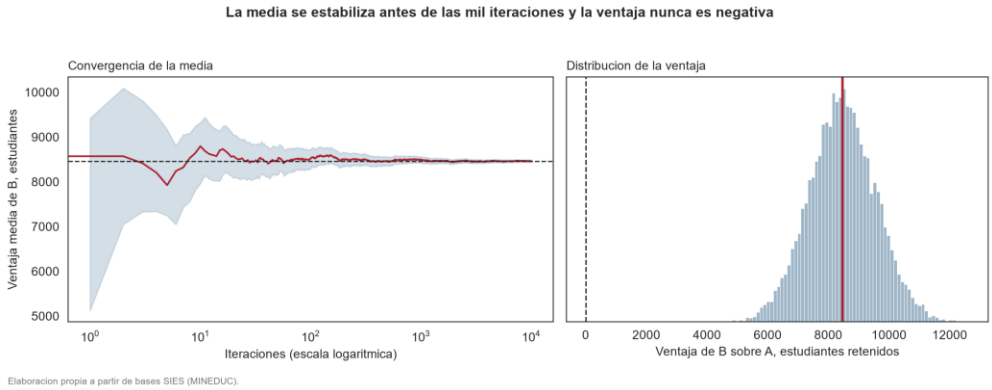


Figura 4. Convergencia de la ventaja media de la estrategia B y distribución de esa ventaja sobre las 10.000 iteraciones.

Focalizar por el abandono observado alcanza a un 38,9 % más de estudiantes: 30.205 frente a 21.742 en el escenario base, una diferencia media de 8.462 estudiantes. La estrategia B supera a la A **en las 10.000 iteraciones**, y el percentil 2,5 de la diferencia, 6.306 estudiantes, queda muy lejos del cero.

La convergencia confirma que el número de iteraciones basta con holgura: el error estándar de Monte Carlo es de 11 estudiantes, un 0,25 % de la magnitud estimada, y bastarían 644 iteraciones para una precisión del 1 %. Verificar convergencia permite separar la incertidumbre del fenómeno —que es grande, como muestra la distribución— de la que introduce el método, que aquí es despreciable.

El resultado **cuantifica la recomendación que la Sumativa 1 dejó enunciada**. Que la acreditación distinga grupos con un efecto grande no la convierte en buen criterio de focalización: los programas de instituciones no acreditadas son demasiado pocos para absorber el presupuesto, y la mayor parte de los programas con abandono alto queda fuera de esa categoría.

6. Análisis de robustez y sensibilidad

6.1 Observaciones influyentes y valores extremos

El **jackknife** sobre los 9.678 programas arroja un error estándar de 0,002276, idéntico al clásico e igual al bootstrap hasta la quinta cifra, y un sesgo estimado nulo. Ninguna observación individual desplaza la media más de $5{,}4 \times 10^{-5}$: **no hay programas influyentes**. El estadístico no depende de ningún caso particular.

La exclusión de los **465 programas censurados** en 0 y en 1, identificados en la fase anterior, desplaza la media del abandono de 0,518 a 0,527 y reduce su desviación típica de 0,224 a 0,199. La correlación con la acreditación de carrera

apenas se mueve, de −0,311 a −0,310, y el contraste de Welch mantiene su decisión. Son cambios pequeños, pero recuerdan que la censura de la variable no es inocua.

6.2 Sensibilidad de la simulación a sus variables de entrada

La comparación entre estrategias es **algebraicamente independiente de ε**, porque ese factor multiplica por igual a ambas y se cancela en el cociente: la conclusión no descansa sobre el supuesto que peor se conoce. Los ejes que sí podrían moverla son el presupuesto y la proporción de instituciones no acreditadas, que determina si la estrategia A dispone de candidatos suficientes.

Ventaja relativa de B (%)	Presupuesto 5 %	10 %	15 %	20 %
No acreditados 9 % (valor S1)	+44,1	+38,8	+43,6	+44,1
No acreditados 20 %	+47,0	+38,9	+32,7	+27,8
No acreditados 35 %	+49,9	+42,7	+36,8	+32,0
No acreditados 50 %	+51,3	+45,6	+40,1	+35,6

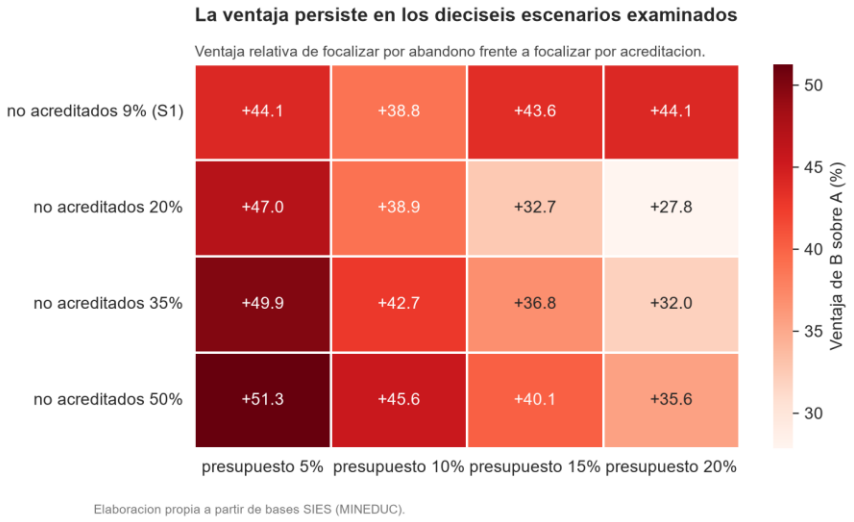


Figura 5. Ventaja relativa de focalizar por abandono en los dieciséis escenarios examinados.

La ventaja se mantiene entre el 28 y el 51 % en los dieciséis escenarios. Ni siquiera multiplicando por cinco la proporción de programas no acreditados la estrategia por acreditación llega a competir. Sustituir además la distribución generadora, de normal truncada a Beta ajustada por momentos a las mismas medias y desviaciones, reduce la ventaja de 8.462 a 7.958 estudiantes —un 6 %— y la estrategia B sigue ganando en el 100 % de las iteraciones: **el resultado no es un artefacto de la forma supuesta** sino una consecuencia de la dispersión del abandono.

Todo lo anterior valida el procedimiento, no el dato. El abandono sigue siendo aparente, la unidad sigue siendo el programa y las asociaciones siguen sin ser causas. Ningún método de remuestreo puede corregir un sesgo de construcción, porque remuestrea exactamente los mismos datos que lo contienen.

7. Resultados validados para la Sumativa 3

El archivo `resultados_validados.csv`, en la raíz del repositorio, recoge en forma legible por máquina el veredicto de cada resultado sometido a validación, junto con los intervalos clásico y bootstrap y las recomendaciones metodológicas. Su contenido se resume así:

Resultado	Veredicto	Base de la decisión
Las cuatro medias y proporciones estimadas	Robustos	IC bootstrap coincide con el clásico, discrepancia < 0,9 %

Resultado	Veredicto	Base de la decisión
Contraste sobre la acreditación	Robusto	Permutación y Welch concuerdan sin supuestos
Tres correlaciones fuertes	Estables	IC bootstrap estrecho y lejos del cero
Correlación con egreso municipal	Débil	Signo definido, magnitud irrelevante
Ventaja de focalizar por abandono	Robusta	Persiste en 16 escenarios y con otra distribución
465 programas censurados	Sensible	Desplazan la media 0,009; conservar y declarar

Recomendaciones metodológicas para la fase siguiente. Reportar los intervalos BCa en lugar de los clásicos: coinciden, de modo que no hay costo, y no dependen de supuestos. Construir el modelo multivariado sobre las tres correlaciones estables y fuertes, dejando las débiles como controles sin interpretación propia. Agrupar los errores estándar por institución, porque los programas de una misma institución no son observaciones independientes. Conservar los 465 programas censurados y declarar su efecto, en lugar de excluirlos. Y declarar siempre como supuesto de política, no como estimación, cualquier parámetro de eficacia de una intervención.

8. Reproducibilidad

Todas las cifras de este informe se generan al ejecutar `S2/Sumativa2_Validacion_Remuestreo.ipynb`, que corre de principio a fin sin errores en poco más de un minuto y deja sus salidas en `S2/resultados/`. Cada procedimiento emplea 10.000 repeticiones y la semilla fijada en 42. El repositorio contiene las carpetas `S1` y `S2` con los entregables de cada fase, el conjunto analítico versionado y los scripts que lo construyeron. Repositorio: https://github.com/santunez75/analisis-desercion