MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento Predictivo Integrado

Informe técnico grupal · 60 %

Título del proyecto:	Análisis de la deserción en la educación superior chilena
Integrantes:	María Fassler Neumann · Sebastian Antunez Noguera — Grupo 4
Dataset:	SIES: matrícula 2007–2026 y titulados 2007–2025 (Mineduc, datos abiertos). 9.678 programas de pregrado, 25 variables.
Docente:	Jean Paul Maidana
Fecha:	20/10/2026
Repositorio GitHub:	https://github.com/santunez75/analisis-desercion

Información de la evaluación	
Fase del proyecto:	Fase 4: Presentación y comunicación
Modalidad:	Grupal
Ponderación:	60 % de la nota final
Entregables:	Informe final PDF (máx. 10 págs.) · Notebook maestro .ipynb · Presentación (video o en vivo) · Repositorio GitHub completo
Resultados de aprendizaje:	RA1, RA2, RA3 (esta evaluación los integra).
Prerrequisitos:	Sumativas 1 y 2 completadas (usarán sus resultados).

Índice

Índice 2
Manejo inteligente de datos faltantes 3
Referencia al análisis de faltantes de S1 3
Imputación mediante regresión lineal múltiple 3
Comparación de estrategias de imputación 4
Clasificación mediante regresión logística 5
Preparación de datos informada por S1 5
Selección de variables informada por S1 y S2 6
Evaluación de estabilidad mediante bootstrap 7
Diagnóstico de supuestos 8
Evaluación de desempeño predictivo 8
Análisis comparativo del impacto de la imputación 9
Informe final integrado 10
Resumen. 10
Metodología integrada. 11
Resultados integrados. 11
Discusión. 11
Conclusiones. 11
Bibliografía (APA 7) 11

Manejo inteligente de datos faltantes

Referencia al análisis de faltantes de S1

El reporte de calidad de la Sumativa 1 no dejó lugar a dudas, ninguna de las 25 variables del conjunto tiene valores faltantes. Las nueve comprobaciones que aplicamos entonces (duplicados de fila, códigos de programa repetidos, valores nulos, valores fuera de dominio y cuatro consistencias aritméticas) devolvieron cero incidencias, salvo dos casos marcados para revisión manual que resultaron ser datos legítimos. El porcentaje de faltantes por variable es 0,0 % en los 25 casos, así que no hay patrón MCAR, MAR ni MNAR que identificar en el sentido de Rubin (1976): no hay ausencia que clasificar.

La razón está en cómo se armó el conjunto analítico, documentado en `datos/origen/`. Cada fila no es un registro original del SIES, sino un agregado por programa: los scripts cruzan las bases de matrícula 2007–2026 y titulados 2007–2025 (SIES, 2026) y calculan la tasa de abandono aparente como cociente de dos conteos. Si a un programa le faltan los campos necesarios para ese cociente, no produce una fila con huecos. No produce fila. La ausencia se resuelve aguas arriba, en la agregación, y el archivo que llega al análisis viene completo por construcción.

Quisimos descartar además que algún paso previo hubiera rellenado los huecos sin declararlo: contamos las coincidencias exactas con la mediana en las cinco variables candidatas y salió cero en todas. No hubo imputación encubierta. Eso nos deja sin nada que imputar sobre el dato real, y el apartado 1.2 lo resuelve sin falsear el diagnóstico.

Imputación mediante regresión lineal múltiple

Optamos por un experimento controlado de ausencia. Eliminamos valores de forma deliberada bajo los tres mecanismos que distingue la literatura (Little y Rubin, 2019) y comparamos cómo se comporta cada estrategia de tratamiento. El diseño tiene una ventaja que el trabajo con faltantes reales no ofrece, conocemos los valores verdaderos, y eso permite medir el error de cada estrategia. Cuando la ausencia es genuina, lo único que cabe hacer es comparar distribuciones y confiar.

La asignación de mecanismos no fue arbitraria. La edad promedio pierde valores al azar, con probabilidad constante (MCAR), y hace de control, porque su ausencia no debería sesgar nada; es el caso que la pauta prescribe, con un 14,9 % de la columna y semilla fija. Los otros dos los declaramos como extensión voluntaria. La proporción de mujeres pierde valores con probabilidad creciente en la duración del programa, que sí se observa (MAR); S2 la había declarado estable y en la Formativa 2 resultó influyente. El logaritmo de la matrícula los pierde con más probabilidad cuanto menor es su propio valor (MNAR), imitando la idea de que los programas pequeños reportan peor. Incluimos el caso MNAR justamente porque ninguna estrategia puede corregirlo del todo.

Tabla 1: Ausencia inducida por mecanismo y sesgo que introduce en la media de la variable afectada, en desviaciones típicas.

Variable	Mecanismo	Faltantes	% de la columna	Media observada	Media verdadera	Sesgo
edad_promedio	MCAR	1.443	14,9 %	24,175	24,160	+0,015
pct_mujeres	MAR	2.368	24,5 %	0,5132	0,5156	−0,002
log_matricula	MNAR	2.377	24,6 %	4,8635	4,7344	**+0,129**

Los mecanismos logísticos producen más ausencia que el MCAR, así que 5.077 de 9.678 filas, el 52,5 %, pierden al menos un valor. La asimetría es deliberada: la ausencia no aleatoria suele ser también la más frecuente.

La última columna trae la lección principal, y no es la que uno esperaría. Bajo MCAR el sesgo es nulo, como corresponde. Bajo MNAR es grande, porque faltan sistemáticamente los programas pequeños y la media observada termina sobreestimando el tamaño típico. Lo llamativo está en el medio: bajo MAR el sesgo de la media es despreciable, de apenas −0,002. La explicación es que la duración, que gobierna la ausencia, casi no correlaciona con la proporción de mujeres; MAR no sesga necesariamente las medias marginales, y lo que distorsiona son las relaciones condicionales. Confundir las dos cosas llevaría a declarar inocua una ausencia que no lo es, y por eso el apartado 1.3 no se queda en comparar medias.

Para cada variable ajustamos una regresión lineal múltiple con entre cuatro y cinco predictoras, elegidas por su |r| en la matriz de correlaciones de S1 y dando prioridad a las que S2 validó como estables. El ajuste emplea únicamente observaciones completas, de modo que el modelo nunca aprende de un valor imputado. El abandono, que es la variable respuesta, no se imputa ni entra como predictora en ninguno de los tres imputadores.

Tabla 2: Ajuste y verificación de supuestos de los tres modelos de imputación.

Variable imputada	Predictoras	n de ajuste	R^2	RMSE	Jarque-Bera p	Breusch-Pagan p	Durbin-Watson
edad_promedio	5	8.235	0,268	3,002	< 0,001	< 0,001	1,379
pct_mujeres	4	5.391	**0,084**	0,287	< 0,001	< 0,001	1,322
log_matricula	5	7.301	0,273	0,585	< 0,001	< 0,001	1,442

Los tres imputadores incumplen los supuestos clásicos. Jarque-Bera y Breusch-Pagan rechazan la normalidad y la homocedasticidad de los residuos con p < 0,001 en los tres casos, y el Durbin-Watson, entre 1,32 y 1,44, advierte de dependencia residual, algo coherente con que los programas se agrupen por institución. Hay que precisar qué implica eso. Si quisiéramos estimar los coeficientes del imputador e inferir sobre ellos, las violaciones importarían bastante; para predecir un valor puntual, que es el único uso que les damos aquí, importan mucho menos, porque la predicción por mínimos cuadrados sigue siendo el mejor predictor lineal insesgado en media, aunque los residuos no sean normales.

Para el resultado pesa más la capacidad predictiva, y ahí las tres variables se comportan muy distinto. El R^2 llega a 0,268 y 0,273 en la edad y el tamaño, pero se queda en 0,084 en la proporción de mujeres. La matriz de S1 ya lo anticipaba, porque ninguna variable se asocia con ella por encima de |r| = 0,16. Donde no hay predictores informativos la imputación por regresión no puede hacer magia, y el apartado siguiente lo confirma con el error medido.

De los 6.188 valores ausentes, la regresión alcanzó a imputar 5.730, el 92,6 %: 1.443 en la edad, 1.910 en la proporción de mujeres y 2.377 en el tamaño. Los 458 restantes caen en filas donde faltaba también `log_matricula`, que es predictora de `pct_mujeres` y es, a la vez, la variable MNAR; en esas filas recurrimos a la mediana para no perderlas. El detalle nos pareció revelador: la ausencia no aleatoria contamina la imputación de las demás variables, porque inutiliza las predictoras.

Comparación de estrategias de imputación

Comparamos las tres estrategias en cuatro dimensiones: El tamaño de muestra que dejan, cuánto alteran la distribución de las variables, si preservan las correlaciones que S1 estimó, criterio que la pauta señala, y el error que cometen frente a los valores verdaderos, que el diseño controlado nos permite medir.

Tabla 3: Comparación de las tres estrategias. El desvío de correlaciones es la media del |error| sobre seis pares estimados en S1; el RMSE se calcula solo sobre los valores efectivamente imputados.

Estrategia	n	% retenido	Desvío medio de las correlaciones de S1	RMSE edad	RMSE % mujeres	RMSE log matrícula
Eliminación de casos	4.601	**47,5 %**	0,0183	—	—	—
Imputación simple (mediana)	9.678	100 %	0,0197	3,641	0,2758	0,685
Imputación por regresión	9.678	100 %	**0,0135**	**2,876**	**0,2732**	**0,616**
Valores verdaderos	9.678	100 %	0 (referencia)	—	—	—

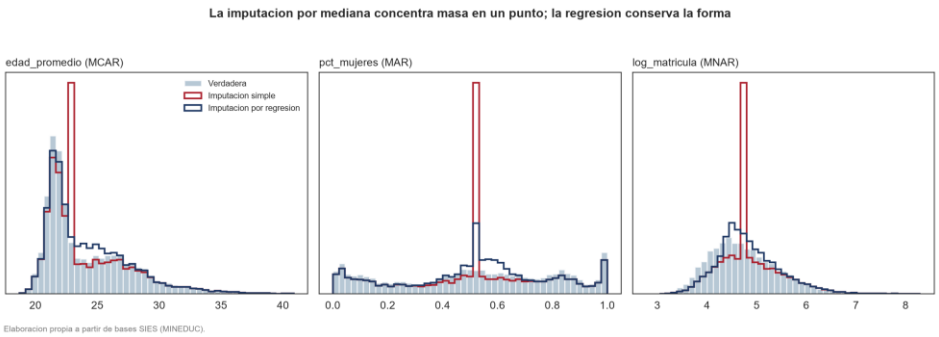


Figura 1: Efecto de cada estrategia sobre la distribución de las tres variables afectadas. La imputación por mediana concentra masa en un punto; la regresión reproduce la forma de la distribución verdadera.

Para el resto del desarrollo adoptamos la imputación por regresión, por tres razones que la tabla documenta.

La primera es que conserva toda la muestra. La eliminación descarta el 52,5 % de los programas, y no al azar, bajo MAR y MNAR se pierden sobre todo los de mayor duración y los pequeños, de manera que el conjunto que sobrevive deja de representar al sistema. Nos parece el defecto más grave de los tres, porque ningún paso posterior lo corrige.

Las otras dos van juntas, preserva mejor las correlaciones de S1 y comete menos error. Su desvío medio, 0,0135, es el menor de los tres, y su RMSE es menor en las tres variables. Que la imputación simple sea la peor en correlaciones no es casualidad: sustituir variabilidad real por una constante atenúa las asociaciones, y se nota en que la desviación típica de lo que imputa es cero. La ventaja de la regresión es amplia donde el imputador tiene poder predictivo (2,876 frente a 3,641 en la edad) y mínima donde no lo tiene (0,2732 frente a 0,2758 en la proporción de mujeres), lo que confirma la lectura del R^2 anterior.

Conviene no estirar la conclusión. Bajo MNAR ninguna estrategia recupera lo perdido: el sesgo medio de lo imputado en `log_matricula` sigue siendo +0,395, porque la ausencia depende del valor que no se observa. La regresión reduce el error, pero no elimina el sesgo. Es una limitación del problema, no del método, y hay que declararla como tal.

Clasificación mediante regresión logística

Preparación de datos informada por S1

La variable respuesta es el abandono dicotomizado en el 50 %, el mismo umbral que estimó S1, donde el 54,94 % de los programas lo supera, y que S2 validó con el intervalo de Wilson, bootstrap y un contraste Z de una proporción. No introducimos aquí ningún umbral nuevo.

Los valores extremos se conservan. S1 identificó 465 programas censurados en 0 y en 1, y S2 los auditó uno a uno: el 91 % de los que tienen abandono igual a uno corresponde a cierres reales de programa, no a errores de registro. La recomendación de esa fase fue conservarlos y declararlos, entre otras cosas porque excluirlos desplaza la media del sistema apenas nueve milésimas. La Parte 3 pone esa decisión a prueba.

La partición es 70/30 estratificada por la respuesta, con la semilla 42 fijada y visible en el cuaderno. La estratificación iguala la prevalencia de abandono alto en ambos conjuntos, un 54,95 % en entrenamiento y un 54,92 % en prueba, con una diferencia de 0,02 puntos, de modo que el desempeño medido no se contamina con un desbalance accidental entre particiones. Quedan 6.774 programas para entrenar y 2.904 para evaluar.

Hay una limitación que preferimos declarar de entrada. La estratificación reparte los programas de una misma institución entre ambos conjuntos, y 138 de las 168 instituciones aparecen en los dos. S2 ya había advertido que esos programas no son observaciones independientes, así que parte del desempeño en prueba puede venir de que el modelo vio otros programas de la misma institución. La partición no lo corrige; el apartado 2.3 lo cuantifica con un bootstrap por institución.

Las variables numéricas se estandarizan, para que los coeficientes sean comparables entre sí y se lean como el efecto de una desviación típica. Las categóricas se codifican con variables indicadoras, tomando como referencia la categoría más numerosa.

Selección de variables informada por S1 y S2

Construimos tres modelos con criterios de selección deliberadamente distintos: uno levantado sobre el conocimiento de las fases anteriores, uno automático y uno austero.

Tabla 4: Los tres modelos logísticos ajustados sobre el conjunto de entrenamiento.

Modelo	Criterio de selección	Variables	Coeficientes	Pseudo R^2	AIC	BIC
M1 — dominio	Correlaciones de S1 validadas por S2, más las categóricas con diferencias de grupo documentadas	7	21	0,1327	8.128,9	**8.272,2**
M2 — stepwise AIC	Selección hacia adelante y atrás minimizando el criterio de Akaike	11	25	0,1361	**8.105,2**	8.275,7
M3 — reducida	Solo el núcleo de cuatro variables continuas que S2 declaró robustas	4	5	0,1146	8.265,9	8.300,0

Cada variable del modelo de dominio entra con su cifra, y eso es lo que nos permite sostener que la selección no es arbitraria. Las cuatro continuas traen su correlación de S1 y su intervalo bootstrap de S2, que en los cuatro casos excluye el cero. Las tres categóricas entran por contrastes de S1.

Tabla 5: Justificación variable por variable del modelo de dominio.

Variable	Cifra de S1	Respaldo de S2	Veredicto
carrera_acreditada	r = −0,311	IC [−0,329; −0,293]	Robusta
inst_acreditada	r = −0,259	IC [−0,278; −0,240]	Robusta
log_matricula	r = −0,247	IC [−0,267; −0,227]	Robusta
pct_mujeres	r = −0,165	IC [−0,184; −0,145]	Robusta
clasificacion_institucion	χ^2 = 102,5 (p < 0,001)	V de Cramér = 0,103	Asociación débil
area_del_conocimiento	F = 44,30 (p < 0,001)	η^2 = 0,040	Efecto pequeño
jornada	0,547 vespertina vs 0,501 diurna	+4,6 puntos	Diferencia relevante

Tabla 6: Coeficientes y razones de momios de las variables continuas de M1. Al estar estandarizadas, cada OR expresa el efecto de una desviación típica. La tabla completa está en `S3/resultados/tablas/odds_ratios_m1.csv`.

Término (estandarizado)	Coeficiente	EE	p	OR	IC 95 % del OR
inst_acreditada	−0,457	0,037	< 0,001 *	**0,633**	[0,589; 0,680]
carrera_acreditada	−0,368	0,030	< 0,001 *	**0,692**	[0,653; 0,733]
log_matricula	−0,328	0,032	< 0,001 *	**0,720**	[0,677; 0,766]
pct_mujeres	−0,272	0,038	< 0,001 *	**0,762**	[0,707; 0,821]

Las cuatro apuntan en la misma dirección: una desviación típica más de acreditación, tamaño o presencia femenina reduce entre un 24 % y un 37 % la probabilidad relativa de abandono alto, y las cuatro son significativas al 0,1 %. Entre las categóricas, los efectos más grandes son Derecho (OR 2,95) y Ciencias Básicas (2,40) por encima de la referencia, y los Centros de Formación Técnica Estatales (0,22), Agropecuaria (0,48) y Salud (0,56) por debajo. El apartado 2.3 muestra que varios de esos efectos categóricos son menos firmes de lo que sugieren sus valores p.

Tabla 7: Razón de momios de las cuatro variables del núcleo en los tres modelos. Las tablas completas de cada uno están en `S3/resultados/tablas/odds_ratios_*.csv`.

Variable (estandarizada)	M1 — dominio	M2 — stepwise AIC	M3 — reducida	Variación	Significancia
inst_acreditada	0,633	0,614	0,667	0,053	*** en los tres**
carrera_acreditada	0,692	0,690	0,676	0,016	*** en los tres**
log_matricula	0,720	0,715	0,715	**0,005**	*** en los tres**
pct_mujeres	0,762	0,771	0,663	0,108	*** en los tres**

El núcleo aguanta bien el cambio de especificación. Las cuatro razones de momios siguen siendo significativas al 0,1 % en los tres modelos y varían poco: cinco milésimas en el tamaño del programa y dieciséis en la acreditación de carrera. La mayor variación es la de la proporción de mujeres, 0,108, que en el modelo reducido baja a 0,663 porque, al no haber categóricas, absorbe parte del efecto del área del conocimiento.

Que el orden y la magnitud se conserven al cambiar el criterio de selección sugiere que el resultado no es un artefacto de una especificación concreta.

Los tres modelos coinciden en el núcleo. El stepwise por AIC agrega cuatro variables (proporción de técnico-profesional, duración, matrícula municipal y edad) y mejora el AIC en 24 unidades, pero empeora el BIC. El modelo reducido se queda solo con las cuatro continuas, y que los tres retengan las mismas cuatro corrobora la selección hecha a priori.

Evaluación de estabilidad mediante bootstrap

S2 aplicó bootstrap a estadísticos simples, como medias, proporciones y correlaciones, y comprobó que sus intervalos clásicos eran fiables. Aquí usamos la misma técnica (Efron y Tibshirani, 1993) sobre un objeto más complejo: los coeficientes del modelo final, cuyos errores estándar dependen de supuestos asintóticos que con muestras finitas pueden fallar.

Ejecutamos dos remuestreos distintos, y la diferencia entre ambos es el resultado más informativo de este apartado. El bootstrap estándar remuestrea observaciones con reemplazo, que es el procedimiento que corresponde a la partición adoptada. El bootstrap por institución remuestrea las 164 instituciones del conjunto de entrenamiento y arrastra con ellas todos sus programas; lo presentamos como extensión y sirve para cuantificar la dependencia que S2 advirtió y que la partición estratificada no corrige. Se completaron 2.000 y 1.999 remuestras, respectivamente.

Tabla 8: Amplitud de los intervalos al 95 % de las variables continuas de M1 según los tres procedimientos.

Término	IC clásico 95 %	IC bootstrap estándar	Amplitud clásica	Amplitud bootstrap	Amplitud por institución	Razón institución / clásico
inst_acreditada	[−0,529 ; −0,385]	[−0,541 ; −0,381]	0,143	0,160	0,432	**3,01**
carrera_acreditada	[−0,426 ; −0,310]	[−0,428 ; −0,311]	0,116	0,117	0,227	1,96
log_matricula	[−0,390 ; −0,266]	[−0,395 ; −0,270]	0,124	0,124	0,224	1,81
pct_mujeres	[−0,346 ; −0,197]	[−0,352 ; −0,196]	0,149	0,156	0,242	1,62

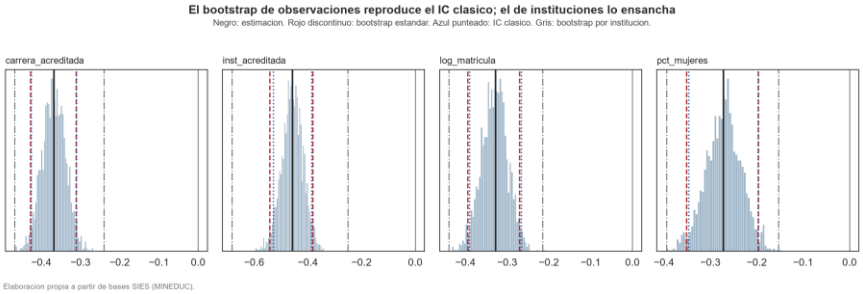


Figura 2: Distribuciones bootstrap de los cuatro coeficientes continuos (2.000 remuestras de observaciones). Las líneas comparan el intervalo clásico, el bootstrap estándar y el bootstrap por institución.

El bootstrap estándar confirma los intervalos clásicos. La razón de amplitudes queda entre 1,00 y 1,12 en las cuatro variables continuas: los intervalos remuestreados reproducen casi exactamente los analíticos. Es el mismo veredicto que S2 emitió sobre medias y correlaciones, ahora extendido a los coeficientes de un modelo, y significa que los errores estándar del ajuste son fiables bajo el muestreo que la pauta supone. De los veinte coeficientes, dieciséis resultan estables y cuatro, todos categóricos, tienen intervalos que cruzan el cero.

El bootstrap por institución cuenta otra historia. Al remuestrear instituciones en lugar de programas, los intervalos se ensanchan entre 1,62 y 3,01 veces respecto de los clásicos, y los coeficientes cuyo signo deja de estar determinado pasan de cuatro a siete de veinte. El caso extremo es la acreditación institucional, cuyo intervalo se triplica.

Las dos conclusiones no se contradicen, porque responden a preguntas distintas. La primera dice que, si los programas fueran independientes, la precisión declarada sería correcta. La segunda dice que no lo son, y que al tenerlo en cuenta la precisión real es entre dos y tres veces menor (Cameron et al., 2008). La dependencia entre programas de una misma institución es la fuente de incertidumbre que el ajuste clásico no ve.

Diagnóstico de supuestos

Tabla 9: Colinealidad y linealidad en el logit de las variables continuas de M1.

Variable	VIF	Lectura	p de Box-Tidwell	Linealidad en el logit
carrera_acreditada	1,21	Tolerable	< 0,001	**No lineal**
inst_acreditada	1,13	Tolerable	< 0,001	**No lineal**
log_matricula	1,12	Tolerable	0,369	Lineal
pct_mujeres	1,03	Tolerable	< 0,001	**No lineal**

La colinealidad no nos da problemas. Los cuatro factores de inflación de varianza quedan por debajo de 1,21, muy lejos del umbral de alarma de 5: cada variable aporta información propia y los coeficientes de la Tabla 6 se pueden leer por separado.

La linealidad en el logit sí se incumple. La prueba de Box-Tidwell (1962) rechaza la hipótesis en tres de las cuatro variables continuas, y solo el tamaño del programa la satisface. El efecto de la acreditación sobre el logaritmo de la razón de momios no es constante a lo largo de su rango, lo que significa que el modelo lineal es una aproximación y que los OR de la Tabla 6 hay que leerlos como efectos promedio, no uniformes. Corregirlo pediría términos polinómicos o una discretización por tramos (Harrell, 2015), y lo dejamos señalado como la mejora más concreta para un trabajo posterior.

Las observaciones influyentes piden más cautela. Ninguna domina el ajuste por sí sola: la distancia de Cook máxima es 0,0095, dos órdenes de magnitud por debajo del umbral habitual de 1 (Cook, 1977), y solo 28 de 6.774 observaciones tienen residuos de Pearson con $|r| > 3$. Pero retirar en bloque las 237 que superan el criterio 4/n cambia el coeficiente de la acreditación institucional en un 87,7 %, y los del tamaño y la proporción de mujeres en un 25,0 % y un 22,1 %, mientras el de la acreditación de carrera se mueve apenas un 3,6 %. No hay contradicción: el conjunto de puntos influyentes tira en una misma dirección, aunque ninguno pese mucho por separado.

De los cuatro coeficientes, el de la acreditación institucional es el menos firme, y eso calza con que su intervalo sea también el que más se ensancha al remuestrear por institución, con una razón de 3,01. Es a la vez la variable de mayor efecto puntual y la de menor solidez, y cualquier recomendación de política que se apoye en ella debería decirlo. Conservamos todas las observaciones, por coherencia con lo que S2 decidió sobre los extremos, pero dejamos declarada la inestabilidad. La calibración, en cambio, es buena: la probabilidad predicha sigue de cerca la frecuencia observada por deciles.

Evaluación de desempeño predictivo

La comparación obligada no es entre modelos, sino contra la línea base: el clasificador trivial que predice siempre la clase mayoritaria. Sin esa referencia, una exactitud de 0,68 no significa nada, porque en un conjunto donde el 54,9 % pertenece a una clase, acertar la mitad de las veces es gratis.

Tabla 10: Desempeño en prueba de los tres modelos frente a la línea base. El cuaderno incluye además las cifras de entrenamiento.

Modelo (conjunto de prueba)	Exactitud	Precisión	Sensibilidad	Especificidad	F1	AUC
Línea base (siempre «alto»)	0,5492	0,5492	1,0000	0,0000	0,7090	0,5000
M1 — dominio	**0,6784**	0,6896	0,7536	0,5867	**0,7202**	0,7301
M2 — stepwise AIC	0,6780	0,6894	0,7530	0,5867	0,7198	**0,7325**
M3 — reducida	0,6612	0,6767	0,7335	0,5730	0,7040	0,7123

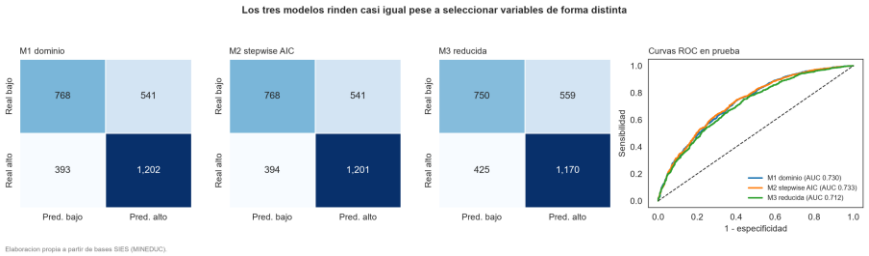


Figura 3: Matrices de confusión en prueba y curvas ROC de los tres modelos.

La ganancia sobre la línea base no es uniforme entre métricas. El clasificador trivial acierta el 54,9 % y obtiene un F1 de 0,709, porque su sensibilidad es 1 por construcción. Frente a eso, M1 sube la exactitud 12,9 puntos y el AUC de 0,500 a 0,730, pero su F1 solo mejora en 0,011. Lo que el modelo aporta es capacidad de discriminación, que es lo que mide el AUC y la línea base no tiene en absoluto, más que mejora del F1, que el clasificador trivial ya infla a base de sensibilidad perfecta. El modelo reducido queda incluso por debajo de la línea base en F1, con 0,704 frente a 0,709, pese a un AUC de 0,712.

Sobreajuste no hay. La brecha de AUC entre entrenamiento y prueba es de +0,010 en M1, +0,011 en M2 y +0,013 en M3: diferencias pequeñas y del signo esperable.

Sobre la ponderación de clase hay que hacer una aclaración. La pauta pide incorporarla para mejorar el recall y en este conjunto el resultado va al revés. La ponderación equilibrada reduce el peso de la clase mayoritaria, y el recetario habitual da por hecho que la clase positiva es la minoritaria; acá pasa lo contrario, porque abandono alto es la mayoritaria con un 54,9 %. Los pesos quedan en 0,910 y 1,110, una razón de apenas 1,22, y el efecto se invierte.

Tabla 11: Cuatro configuraciones del modelo final sobre el conjunto de prueba. El AUC es idéntico en todas: ninguna palanca cambia el orden de las probabilidades, solo el punto de corte.

Configuración	Exactitud	Precisión	Sensibilidad	Especificidad	F1	AUC
Línea base (siempre «alto»)	0,549	0,549	1,000	0,000	0,709	0,500
Sin ponderar, umbral 0,50	0,678	0,690	0,754	0,587	0,720	0,730
Con ponderación de clase, umbral 0,50	0,664	0,702	**0,674**	0,652	0,688	0,730
Sin ponderar, umbral de Youden 0,508	0,678	0,694	0,742	0,601	0,717	0,730
Sin ponderar, **umbral 0,418**	0,672	0,655	**0,850**	0,455	**0,740**	0,730

La ponderación baja la sensibilidad casi ocho puntos, de 0,754 a 0,674, y sube la especificidad de 0,587 a 0,652. El AUC no se mueve, 0,7301 frente a 0,7300, lo que confirma la lectura: la ponderación no altera el orden en que el modelo clasifica los programas, solo desplaza el corte efectivo. El umbral de Youden tampoco aporta nada, porque sale en 0,508, prácticamente el 0,50 de partida; con las clases casi equilibradas no hay un corte oculto que mejore las dos métricas a la vez.

La palanca que sí sube el recall es bajar el umbral. Con 0,418 la sensibilidad llega a 0,850, al precio de 13,1 puntos de especificidad y 3,4 de precisión. Para el uso que tenemos en mente el intercambio es favorable, porque omitir un programa en riesgo cuesta más que revisar uno sano. Y hay un argumento que no depende de esa preferencia: esa configuración consigue el mejor F1 de todas, 0,740, frente a 0,720 del umbral 0,50 y 0,709 de la línea base. Al umbral por defecto el modelo apenas le gana al clasificador trivial en F1; al 0,418 le gana con holgura. En este problema, elegir el umbral pesa más que ponderar y más que elegir entre los tres modelos.

Para el modelo final nos quedamos con M1, el de dominio. Las diferencias entre los tres son pequeñas, con AUC de 0,712 a 0,733, así que la decisión no se juega en el desempeño. Pesó, primero, que M1 no fue seleccionado con estos datos: lo especificamos a partir de S1 y S2 antes de mirar el conjunto de entrenamiento, mientras que M2 se eligió sobre los mismos datos con los que después se ajusta, de modo que su ventaja de tres milésimas de AUC está sesgada al alza por el propio proceso de selección (Harrell, 2015). Segundo, que cada variable tiene una justificación documentada, la de la Tabla 5. Y tercero, que M3 resulta demasiado austero: prescindir de las categóricas cuesta dos centésimas de AUC y lo deja bajo la línea base en F1, sin ganar interpretabilidad.

Análisis comparativo del impacto de la imputación

La decisión del apartado 1.3 se pone a prueba ajustando el mismo modelo final sobre los tres conjuntos, con la misma partición 70/30 estratificada. La pregunta no es cuál rinde mejor, sino si la elección de la estrategia modifica las conclusiones.

Tabla 12: El modelo final ajustado sobre los tres conjuntos. La amplitud del IC se promedia sobre las cuatro variables continuas.

Estrategia	n	n entrenamiento	AUC prueba	Exactitud	F1	coef inst_acreditada	Amplitud media del IC
Eliminación	4.601	3.220	0,7568	0,6973	0,7224	−0,429	**0,199**
Imputación simple	9.678	6.774	0,7303	0,6729	0,7156	−0,452	0,132
Imputación por regresión	9.678	6.774	0,7301	**0,6784**	**0,7202**	−0,457	0,133

Las conclusiones del modelo no cambian. El signo de los cuatro coeficientes se mantiene en los tres conjuntos y su orden de importancia casi no se altera, con la acreditación institucional encabezando en los tres. En ese sentido el análisis es robusto frente a la estrategia de imputación, que es justamente lo que la pauta pide verificar.

La precisión sí cambia, y de manera sistemática. La eliminación produce intervalos un 50 % más anchos en promedio, 0,199 frente a 0,132 y 0,133, simplemente porque trabaja con menos de la mitad de los datos: paga la limpieza con incertidumbre. Y hay un punto que la tabla deja a la vista: las dos imputaciones producen intervalos casi idénticos entre sí, porque ambas devuelven n = 9.678. El estrechamiento no premia la calidad de la imputación, solo el tamaño de muestra que se recupera.

De ahí sale la limitación más importante de esta parte. Ninguna de las dos imputaciones propaga la incertidumbre de haber imputado: las dos tratan un valor predicho como si fuera observado, y por eso sus intervalos quedan demasiado estrechos, aunque coincidan entre sí. Corregirlo exige imputación múltiple con las reglas de combinación de Rubin (Little y Rubin, 2019), que se sale del alcance de esta fase y queda como la extensión natural del trabajo.

Un detalle que no habría que malinterpretar. La eliminación obtiene el AUC de prueba más alto, 0,757 frente a 0,730, pero ese número no es comparable con los otros dos: su conjunto de prueba es distinto y más pequeño, porque descartó filas antes de particionar, y un AUC mayor sobre un conjunto más fácil y menos representativo no indica un mejor modelo. Entre las dos imputaciones, que sí son comparables, la regresión supera a la mediana en exactitud, 0,678 frente a 0,673, y en F1, 0,720 frente a 0,716.

De todo esto salen cuatro recomendaciones. Preferir la imputación por regresión, que conserva la muestra, preserva mejor la estructura de correlaciones y rinde algo más que la mediana. No eliminar casos cuando la ausencia no es MCAR, porque el conjunto que sobrevive deja de representar al sistema. Declarar siempre el mecanismo supuesto, porque bajo MNAR ninguna estrategia es insesgada y pretender lo contrario es el peor error posible. Y tratar como optimistas los intervalos que vienen después de una imputación simple, salvo que se use imputación múltiple.

Informe final integrado

Resumen.

Sobre 9.678 programas de pregrado del sistema chileno de educación superior, el abandono aparente resulta anticipable en parte. Un modelo de regresión logística con siete variables alcanza un AUC de 0,730 en prueba y suma 12,9 puntos de exactitud sobre la línea base, lo que alcanza para priorizar programas, pero no para dictaminar sobre uno en particular. Cuatro factores sostienen esa capacidad y los cuatro reducen el riesgo: la acreditación institucional (OR 0,633 por desviación típica), la acreditación de la carrera (0,692), el tamaño del programa (0,720) y la proporción de mujeres (0,762). Son las mismas cuatro que resistieron el remuestreo en S2 y que retienen las tres selecciones de variables. El resultado metodológico que más nos importa es un contraste: el bootstrap estándar confirma los intervalos clásicos, con una razón de amplitudes de 1,00 a 1,12, pero el bootstrap por institución los ensancha entre 1,62 y 3,01 veces, porque los programas de una misma institución no son independientes.

Introducción.

El abandono se mide aquí a nivel de programa y en su versión *aparente*: la fracción de una cohorte de matriculados que no aparece titulada en el mismo programa. La pregunta práctica que organiza el proyecto es si ese abandono puede anticiparse a partir de atributos observables, para focalizar recursos de retención antes de que el problema se consolide.

Metodología integrada.

Lo que define a esta fase es que casi ninguna decisión metodológica es nueva. Las predictoras de los imputadores salen de la matriz de correlaciones de S1; las variables del modelo, del filtro de estabilidad de S2, con su cifra cada una; el tratamiento de los 465 censurados, de la auditoría caso a caso que hizo S2; el umbral del 50 %, de S1 validado en S2; y el bootstrap de los coeficientes es el instrumento de S2 trasladado a un objeto más complejo. La cadena queda explícita: S1 describió y midió, S2 puso a prueba y validó, S3 modela y predice sobre lo que quedó en pie.

Resultados integrados.

S1 estableció el abandono medio en 0,518 y nueve variables asociadas. S2 confirmó por bootstrap que los intervalos clásicos eran fiables, validó el contraste por permutación, separó las correlaciones sólidas de las débiles y cuantificó por Monte Carlo la ventaja de focalizar, que es un 38,9 % más de estudiantes alcanzados. S3 integra todo eso en un clasificador y agrega cuatro resultados propios. El mecanismo de ausencia importa más que su porcentaje, y bajo MNAR ninguna estrategia es insesgada. La imputación por regresión le gana a las otras dos en error y en preservación de correlaciones. La precisión del modelo es fiable bajo muestreo independiente, pero entre dos y tres veces menor al reconocer la dependencia institucional. Y el umbral de decisión pesa más que la ponderación de clase y que la elección entre los tres modelos.

Discusión.

Hay cuatro tensiones que preferimos dejar escritas. La capacidad predictiva es moderada: un AUC de 0,730 ordena bien el conjunto, pero deja margen de error alto en el caso individual. La ganancia en F1 depende del umbral: al 0,50 el modelo apenas supera la línea base, 0,720 frente a 0,709, mientras que al 0,418 la supera con holgura, 0,740. El modelo lineal en el logit es una aproximación, porque Box-Tidwell lo rechaza en tres de las cuatro variables continuas. Y el coeficiente de la acreditación institucional es el menos firme de todos: su intervalo es el que más se ensancha al remuestrear por institución, y retirar las 237 observaciones influyentes lo mueve un 87,7 %. Es la variable de mayor efecto puntual y, a la vez, la de menor solidez.

Conclusiones.

El abandono aparente se asocia de forma robusta con la acreditación, el tamaño y la composición de género, y un modelo construido sobre esas variables sirve para priorizar, con el umbral fijado según el costo relativo de los dos errores. No permite afirmar nada sobre estudiantes individuales, porque la unidad de análisis es el programa; nada sobre causas, porque no hay grupo de control; nada sobre el abandono real, porque lo que medimos es el aparente; y nada firme sobre los efectos categóricos, que pierden el signo al remuestrear por institución. La extensión natural del trabajo es triple: imputación múltiple, términos no lineales donde Box-Tidwell los exige y un modelo multinivel que trate la institución como efecto aleatorio.

Bibliografía (APA 7)

- Box, G. E. P., y Tidwell, P. W. (1962). Transformation of the independent variables. *Technometrics, 4*(4), 531–550. https://doi.org/10.1080/00401706.1962.10490038
- Cameron, A. C., Gelbach, J. B., y Miller, D. L. (2008). Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics, 90*(3), 414–427. https://doi.org/10.1162/rest.90.3.414
- Cook, R. D. (1977). Detection of influential observation in linear regression. *Technometrics, 19*(1), 15–18. https://doi.org/10.1080/00401706.1977.10489493
- Efron, B., y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.
- Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.ª ed.). Springer.

- Harrell, F. E. (2015). *Regression modeling strategies: With applications to linear models, logistic and ordinal regression, and survival analysis* (2.ª ed.). Springer.
- Hosmer, D. W., Lemeshow, S., y Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley.
- Little, R. J. A., y Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley.
- Rubin, D. B. (1976). Inference and missing data. *Biometrika, 63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581
- Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics, 6*(2), 461–464. https://doi.org/10.1214/aos/1176344136
- Servicio de Información de Educación Superior. (2026). *Bases de datos de matriculados y titulados en educación superior*. Ministerio de Educación de Chile. https://www.mifuturo.cl/bases-de-datos-de-matriculados/